

**Model Prediksi *Ground Flash Density* (GFD) Petir
Wilayah Tropis serta Petir Wilayah Subtropis
Berbasis Komputasi Kuantum dengan Framework
Qiskit**

Proposal Tugas Akhir

Oleh

**Muhammad Rafly
18222067**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
5 Desember 2025**

LEMBAR PENGESAHAN

Model Prediksi *Ground Flash Density* (GFD) Petir Wilayah Tropis serta Petir Wilayah Subtropis Berbasis Komputasi Kuantum dengan Framework Qiskit

Proposal Tugas Akhir

Oleh

**Muhammad Rafly
18222067**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 5 Desember 2025

Pembimbing 1

Pembimbing 2

Dr. Lenny Putri Yulianti, S.T., M.T.

NIP. 119110073

Dr. Bryan Denov, S.T., M.T.

NIP. 119110078

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	4
I.3 Tujuan	4
I.4 Batasan Masalah	4
I.5 Metodologi	5
II STUDI LITERATUR	6
II.1 Meteorologi Petir dan Ground Flash Density (GFD)	6
II.1.1 Konsep Dasar dan Metrik GFD	6
II.1.2 Faktor Meteorologis Pembentuk Petir	7
II.1.3 Disparitas Karakteristik: Tropis vs. Subtropis	7
II.2 Pendekatan Machine Learning Klasik	8
II.2.1 Algoritma Deep Learning (CNN/LSTM) untuk Nowcasting	8
II.2.2 Keterbatasan Komputasi Klasik	9
II.3 Landasan Teori Komputasi Kuantum	10
II.3.1 Qubit dan Ruang Hilbert	10
II.3.2 Quantum Data Encoding/Feature Map	11
II.4 Arsitektur Model Kuantum	12
II.4.1 Variational Quantum Circuits (VQC)	12
II.4.2 QNN vs. QSVM	13
II.5 Implementasi pada Framework Qiskit	14
II.5.1 Komponen Ekosistem Qiskit	14
II.5.2 Penanganan Noise pada Era NISQ	15
II.6 Tinjauan Penelitian Terdahulu dan Gap Analisis	16
II.6.1 Review Penelitian Terdahulu (QML in Meteorology)	16
II.6.2 Identifikasi Gap Penelitian	18
III ANALISIS MASALAH	20
III.1 Analisis Kondisi Saat Ini	20

III.2 Analisis Kebutuhan	21
III.2.1 Identifikasi Masalah Pengguna	21
III.2.2 Kebutuhan Fungsional	22
III.2.3 Kebutuhan Nonfungsional	23
III.3 Analisis Pemilihan Solusi	24
III.3.1 Alternatif Solusi	24
III.3.2 Analisis Penentuan Solusi	24
IV DESAIN KONSEP SOLUSI	26
V RENCANA SELANJUTNYA	29

DAFTAR GAMBAR

DAFTAR TABEL

DAFTAR KODE

BAB I

PENDAHULUAN

Bab pendahuluan menguraikan dasar pemikiran dan kerangka kerja awal dalam penyusunan tugas akhir. Pembahasan dimulai dengan pemaparan latar belakang yang menjelaskan urgensi serta motivasi pemilihan topik, diikuti dengan rumusan masalah yang mendetailkan inti persoalan yang akan diselesaikan. Selanjutnya, dipaparkan tujuan yang menjadi target pencapaian serta batasan masalah untuk memperjelas ruang lingkup pembahasan. Bab ini diakhiri dengan penjelasan metodologi yang menjabarkan tahapan sistematis yang dilakukan guna menjawab permasalahan tersebut.

I.1 Latar Belakang

Petir adalah pelepasan muatan listrik transien berarus tinggi di atmosfer dengan panjang lintasan yang diukur dalam kilometer (Society 2022). ... PENJELASAN GFD SECARA SINGKAT.

Sambaran petir merupakan fenomena alam yang menjadi sumber risiko signifikan bagi manusia, struktur (misalnya, bangunan sipil dan turbin angin), infrastruktur (misalnya, transmisi dan distribusi tenaga listrik, serta sistem telekomunikasi), perkotaan, penerbangan, dan lingkungan alam (Nicora dkk. June 2024). Data satelit global menunjukkan bahwa terjadi sekitar 46 sambaran petir setiap detiknya di seluruh dunia, yang mengakibatkan lebih dari 10.000 korban jiwa dan kerugian ekonomi melebihi satu miliar USD setiap tahun (Wang dkk. November 2023). Sambaran petir menimbulkan dampak destruktif yang meliputi kerusakan struktur bangunan, risiko kebakaran, kegagalan peralatan, hingga ancaman fatalitas bagi manusia (Achmad Imam Agung dan Mahendra Widayarto 2020). Berdasarkan statistik kegagalan tangki minyak, kebakaran tangki minyak yang disebabkan oleh petir terjadi hampir setiap tahun di Indonesia dalam kurun waktu 1995 hingga 2021. Kilang-kilang

minyak di seluruh Indonesia terpaksa berhenti beroperasi akibat sambaran petir, yang menyebabkan banyaknya kasus kebakaran tangki serta kerusakan pada peralatan elektronik dan berbasis mikroprosesor sejak tahun 1995 (Denov dkk. 2022).

Indonesia, sebagai negara tropis yang dikelilingi oleh lautan dan memiliki arus udara naik (*updraft*) tinggi, menghadapi tantangan-tantangan unik. Indonesia memiliki hutan tropis yang luas sehingga tingkat kelembapannya tinggi. Selain itu, keberadaan banyak industri dan uap garam laut menyebabkan tingginya kandungan aerosol. Kondisi ini membuat wilayah Indonesia sangat kondusif bagi pembentukan awan Kumulonimbus yang menghasilkan petir. Di Indonesia, awan Kumulonimbus (CB) lebih lebar dibandingkan awan CB di wilayah subtropis. Petir di Indonesia memiliki gelombang ekor yang panjang (*long tail wave*), sehingga parameter mutu arusnya lebih besar dibandingkan dengan petir subtropis. Kerapatan sambaran petir di lokasi-lokasi tersebut juga relatif lebih tinggi (Denov dkk. 2022).

Model cuaca yang lebih akurat sangat dibutuhkan untuk memberikan peringatan dini yang lebih baik, mengurangi dampak bencana cuaca ekstrem, dan merencanakan mitigasi yang lebih efektif (Rith, Vann, dan Santos June 2025). Prediksi cuaca yang lebih akurat dapat meningkatkan kesiapsiagaan masyarakat dan mengurangi kerugian akibat bencana alam (Rith, Vann, dan Santos June 2025). Secara khusus, insinyur listrik membutuhkan data lokasi sambaran dan arus puncak dalam prosedur yang bertujuan untuk mengukur risiko petir bagi suatu struktur atau infrastruktur serta merancang sistem proteksi petir yang sesuai (Nicora dkk. June 2024). Statistik tersebut diharapkan dapat membantu insinyur dalam merancang sistem proteksi petir yang tepat berdasarkan data petir lokal (Denov dkk. 2022). Pada akhirnya, kemampuan prediktif ini sangat krusial bagi keselamatan jiwa, perlindungan harita benda, dan pemeliharaan keselamatan infrastruktur vital (Wang dkk. November 2023).

Saat ini, terdapat berbagai model prediksi petir yang memanfaatkan pendekatan tradisional, algoritma *machine learning*, serta teknik *deep learning*. Prediksi model numerik, yang mendasari sebagian besar metode prakiraan petir tradisional, memanfaatkan prinsip-prinsip dari dinamika atmosfer, termodinamika, dan bidang terkait untuk merumuskan model yang mensimulasikan proses atmosfer. Namun, akurasi model-model ini memerlukan peningkatan dikarenakan kompleksnya proses fisik multi-skala yang terlibat dalam kejadian petir (Wang dkk. November 2023). Algoritma *machine learning* tradisional mencakup *decision trees* (DT), *support vector machines* (SVM), *random forests* (RF), *naive Bayes*, dan *simple ANNs*. Metode-

metode ini sangat bergantung pada ekstraksi fitur manual, dengan konstruksi fitur secara manual menjadi komponen penting saat menerapkan algoritma *machine learning* tradisional ini dalam prediksi petir (Wang dkk. November 2023). Terbukti, metode *deep learning*, khususnya *CNN* dan *RNN*, telah menunjukkan kinerja yang luar biasa saat menangani data spasial dan temporal multi-dimensi yang kompleks. Akurasi model-model tersebut masih menjadi area yang perlu ditingkatkan. Metodologi yang sederhana ini dapat mengabaikan keterkaitan yang rumit di antara parameter pengamatan atau fisika dasar yang memicu terjadinya petir (Wang dkk. November 2023).

Perkembangan terkini di bidang-bidang yang berdekatan (*adjacent fields*) telah menunjukkan keberhasilan penerapan komputasi kuantum dalam memecahkan permasalahan yang kompleks. Keunggulan dari model kuantum berasal dari sifat-sifat kuantum seperti *superposition* dan *entanglement*, yang memungkinkan kapasitas pemrosesan yang lebih besar dan identifikasi pola-pola kompleks yang mungkin tidak akan terdeteksi oleh model komputasi klasik (Silva dkk. 2025). Keberhasilan teknologi komputasi kuantum dalam bidang-bidang seperti optimasi dan pemodelan material menunjukkan bahwa teknologi ini memiliki potensi besar untuk menyelesaikan masalah yang berkaitan dengan kompleksitas dan ketidakpastian dalam sistem cuaca (Rith, Vann, dan Santos June 2025). Dalam penelitian meteorologi, komputasi kuantum telah mulai digunakan untuk mengembangkan algoritma dan model prediksi cuaca yang lebih efektif. Penelitian juga menunjukkan bahwa komputasi kuantum dapat membantu mempercepat simulasi iklim dan cuaca yang lebih kompleks, dengan meningkatkan kecepatan analisis data atmosfer yang besar dan meningkatkan pemrosesan data yang lebih efisien (Rith, Vann, dan Santos June 2025). Komputasi kuantum dengan studi-studi yang ada saat ini berfokus pada prediksi kecepatan angin, iradiansi matahari, pembangkitan daya angin dan fotovoltaik, badai geomagnetik, evapotranspirasi, dan presipitasi (Silva dkk. 2025).

Petir sebagai fenomena alam kuat menyebabkan kerusakan masif dan risiko kesehatan. Hal ini menjadi isu kritis di Indonesia yang memiliki densitas petir tinggi dan tantangan geografis yang unik. Untuk memitigasi risiko ini, memprediksi parameter petir secara akurat sangatlah penting. Namun, penelitian saat ini masih bergantung pada *artificial intelligence* (AI) standar. Meskipun komputasi kuantum sudah menangani parameter cuaca, terdapat kekosongan penelitian (*gap*) di mana kuantum belum diterapkan secara spesifik untuk prediksi petir.

I.2 Rumusan Masalah

Berdasarkan uraian di atas mengenai tantangan prediksi cuaca ekstrem dan evolusi teknologi komputasi, maka rumusan masalah yang diajukan dalam penelitian ini adalah:

1. Bagaimana merancang arsitektur *Variational Quantum Circuit* (VQC) atau *Quantum Neural Network* (QNN) pada framework Qiskit yang optimal untuk mengolah parameter input petir guna memprediksi nilai *Ground Flash Density* (GFD)?
2. Bagaimana karakteristik dan akurasi model kuantum tersebut dalam membedakan pola GFD pada wilayah Tropis dibandingkan dengan wilayah Subtropis, serta apakah model mampu melakukan generalisasi pada kedua domain data tersebut?
3. Bagaimana memformulasikan pemetaan matematis (mapping) dari parameter yang telah terlatih menjadi suatu fungsi prediksi yang dapat menerima input variabel atmosfer untuk menghasilkan nilai estimasi GFD?

I.3 Tujuan

Berdasarkan perumusan masalah dan latar belakang, maka tujuan yang diajukan dalam penelitian ini adalah:

1. Membangun dan mengimplementasikan model prediksi GFD berbasis algoritma kuantum menggunakan Qiskit dengan teknik data encoding yang tepat.
2. Mengevaluasi performa model dalam memprediksi GFD pada dataset wilayah Tropis dan Subtropis, serta menganalisis keunggulan atau kelemahan komputasi kuantum dibanding metode klasik pada dataset ini.
3. Menghasilkan suatu model komputasi (fungsi prediktor) yang tervalidasi, di mana parameter cuaca/petir dapat diinputkan ke dalam sirkuit kuantum yang telah dioptimasi untuk mengeluarkan nilai GFD.

I.4 Batasan Masalah

Tuliskan batasan-batasan yang diambil dalam pelaksanaan tugas akhir. Batasan ini dapat dihindari (bersifat opsional, tidak perlu ada) jika topik atau judul tugas akhir dibuat cukup spesifik.

1. Pembangunan solusi dengan memanfaatkan Qiskit sebagai *stack* untuk komputasi kuantum dan riset algoritma yang disimulasikan pada komputer pribadi.
2. Data yang digunakan pada pelaksanaan tugas akhir diperoleh dari

I.5 Metodologi

Tuliskan semua tahapan yang akan dilalui selama pelaksanaan tugas akhir. Tahapan ini spesifik untuk menyelesaikan persoalan tugas akhir. Khusus untuk penyusunan proposal ini, jelaskan secara detail:

Menerapkan protokol PRISMA dan Concept Matrix (Webster Watson) untuk studi literatur

CRISP-DM untuk pengembangan model

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

BAB II

STUDI LITERATUR

II.1 Meteorologi Petir dan Ground Flash Density (GFD)

II.1.1 Konsep Dasar dan Metrik GFD

Pengukuran dan pemodelan Ground Flash Density (GFD) sangat bergantung pada ketersediaan data petir yang andal dari pengamatan satelit. Sensor satelit seperti Lightning Imaging Sensor (LIS) dan Optical Transient Detector (OTD) mencatat petir sebagai “events” pada array pencitraan CCD, yang merepresentasikan peristiwa optik mentah akibat kilatan cahaya petir. [A Global LIS OTD Climatology of Lightning Flash Extent Density.pdf] Untuk mengidentifikasi sambaran petir yang sesungguhnya, data events ini harus melalui tahap pemrosesan tambahan berupa filtering dan clustering, sehingga diperoleh struktur data bertingkat berupa “groups”, “flashes”, dan “areas”. [A Global LIS OTD Climatology of Lightning Flash Extent Density.pdf]

Dalam pemrosesan standar LIS/OTD, “groups” didefinisikan sebagai klaster iluminasi puncak awan dari pulsa-pulsa cahaya individu, “flashes” didefinisikan sebagai rangkaian pulsa yang menggambarkan satu kilat yang utuh, sedangkan “areas” merepresentasikan klaster aktivitas petir yang menggambarkan snapshot badai. [A Global LIS OTD Climatology of Lightning Flash Extent Density.pdf] Dalam konteks GFD, penting untuk membedakan antara events, groups, dan flashes karena GFD didefinisikan sebagai jumlah sambaran petir ke darat (ground flashes) per satuan luas dan waktu (misalnya per km^2 per tahun), sehingga skema klasifikasi ini menjadi dasar untuk menghitung densitas sambaran yang menjadi target prediksi. [A Global LIS OTD Climatology of Lightning Flash Extent Density.pdf] LIS/OTD berfungsi sebagai salah satu sumber ground truth global utama yang relevan untuk memvalidasi model-model prediksi GFD, termasuk model berbasis komputasi kuantum yang dikembangkan pada tesis ini. [A Global LIS OTD Climatology of

Lightning Flash Extent Density.pdf]

II.1.2 Faktor Meteorologis Pembentuk Petir

Pembentukan petir sangat dipengaruhi oleh kondisi termodinamika dan dinamika atmosfer yang dapat direpresentasikan melalui variabel-variabel meteorologis skala besar. Pada sebuah studi parameterisasi petir berbasis machine learning, himpunan data pelatihan dirangkum dalam suatu tabel dengan variabel input yang mencakup presipitasi (P) dan berbagai variabel medan atmosfer, seperti convective available potential energy (CAPE), ketinggian geopotensial 500 hPa (Z500), ketinggian geopotensial 1000 hPa (Z1000), ketebalan antara level 300–700 hPa (Z300–700), suhu pada 2 m (T2M), kecepatan vertikal pada 500 hPa, serta suhu titik embun pada 2 m (2-m dewpoint temperature). [Machine Learning-Based Lightning Parameterizations for the CONUS.pdf]

CAPE pada studi tersebut digunakan sebagai indikator utama ketidakstabilan atmosfer yang mendukung konveksi kuat, sedangkan presipitasi (P) dan suhu titik embun 2 m secara langsung terkait dengan ketersediaan uap air dan kelembaban yang menjadi prasyarat pembentukan awan konvektif dan petir. [Machine Learning-Based Lightning Parameterizations for the CONUS.pdf] Variabel-variabel atmosfer skala besar ini terbukti penting dalam parameterisasi petir dan, dalam konteks tesis ini, dapat difungsikan sebagai fitur input klasik untuk model Quantum Neural Network (QNN) yang dikembangkan untuk memprediksi GFD. [Machine Learning-Based Lightning Parameterizations for the CONUS.pdf]

II.1.3 Disparitas Karakteristik: Tropis vs. Subtropis

Indonesia digambarkan sebagai negara tropis yang terletak di sekitar ekuator dan dikelilingi oleh lautan, sehingga mengalami cuaca panas sepanjang tahun. [A Method to Obtain Lightning Peak Current in Indonesia.pdf] Karakter maritim dengan banyak pulau ini menghasilkan aerosol dalam jumlah besar, terutama dari garam laut, sedangkan iklim yang lembab dengan hutan, sungai, dan danau yang melimpah menjadi faktor utama pembentukan awan kumulonimbus (CB) sebagai awan penghasil petir. [A Method to Obtain Lightning Peak Current in Indonesia.pdf] Kondisi-kondisi ini menjadikan wilayah tropis maritim seperti Indonesia sangat kondusif terhadap aktivitas petir yang intensif. [A Method to Obtain Lightning Peak Current in Indonesia.pdf]

Studi lain menegaskan bahwa terdapat disparitas yang signifikan antara perilaku

petir di iklim tropis dan subtropis. [Review of NFPA 780 Standard Compliance for Improved.pdf] Investigasi ekstensif selama delapan tahun di Stasiun Penelitian Petir Gunung Tangkuban Perahu menemukan berbagai karakteristik unik petir tropis, menandakan bahwa karakteristik kilat di wilayah tropis tidak dapat secara langsung disamakan dengan petir di wilayah subtropis. [A Method to Obtain Lightning Peak Current in Indonesia.pdf] Perbedaan ini menjelaskan perlunya model prediksi yang secara eksplisit mempertimbangkan perbedaan iklim tropis dan subtropis, terutama ketika standar proteksi petir internasional yang dominan berbasis pada karakteristik subtropis hendak diterapkan di wilayah tropis. [Review of NFPA 780 Standard Compliance for Improved.pdf]

II.2 Pendekatan Machine Learning Klasik

II.2.1 Algoritma Deep Learning (CNN/LSTM) untuk Nowcasting

Dalam ranah prediksi petir berbasis komputasi klasik, deep learning telah mencapai tingkat kompleksitas arsitektur yang tinggi. Salah satu contoh adalah model LightningNet yang menggunakan arsitektur encoder-decoder dengan 20 lapisan konvolusional tiga dimensi, lapisan pooling dan upsampling, lapisan normalisasi, serta softmax classifier. [A Deep Learning Network for Cloud-to-Ground Lightning.pdf] Arsitektur ini dirancang untuk memproses data multi-sumber dalam format spasial atau citra, seperti data satelit, radar, dan lokasi petir, sehingga mampu melakukan nowcasting petir cloud-to-ground (CG) dengan resolusi yang tinggi. [A Deep Learning Network for Cloud-to-Ground Lightning.pdf] Model-model seperti LightningNet, LightNet, dan LightNet+ menunjukkan bahwa prediksi petir modern menuntut pemrosesan informasi spasial yang sangat kompleks, yang menjadi tolok ukur kinerja bagi model QNN yang akan dikembangkan. [A Deep Learning Network for Cloud-to-Ground Lightning.pdf]

Di sisi lain, recurrent neural networks (RNN) dirancang khusus untuk memproses data urutan (sequence data) dengan memprosesnya secara iteratif dalam arah sekuensial. [A Survey of Deep Learning-Based Lightning Prediction.pdf] Dalam konteks prediksi petir, RNN sering direalisasikan sebagai long short-term memory (LSTM) yang dikembangkan untuk mengatasi masalah long-term dependencies yang sulit ditangani oleh RNN standar. [A Survey of Deep Learning-Based Lightning Prediction.pdf] Prediksi GFD yang memanfaatkan deret waktu variabel-variabel meteorologis seperti CAPE dan kelembaban dari waktu ke waktu sangat relevan dengan kemampuan LSTM dalam menangkap ketergantungan temporal jangka panjang. [A Survey of Deep Learning-Based Lightning Prediction.pdf] Kombinasi

CNN dan LSTM menghasilkan arsitektur ConvLSTM yang lazim digunakan untuk prediksi spatiotemporal dalam meteorologi, dan fakta ini menandakan bahwa QNN yang dikembangkan dalam penelitian ini juga harus mampu menangani dependensi temporal secara efektif. [A Survey of Deep Learning-Based Lightning Prediction.pdf]

II.2.2 Keterbatasan Komputasi Klasik

Penggunaan Earth Observation (EO) dan data cuaca dalam jumlah besar untuk prediksi cuaca ekstrem menyebabkan kompleksitas waktu komputasi yang sangat tinggi pada pendekatan komputasi klasik. [Assessment of Quantum ML Applicability for Climate Actions.pdf] Studi deep learning untuk prediksi petir, seperti LightningNet, menunjukkan bahwa model tersebut memiliki parameter yang dapat dilatih dalam jumlah sangat besar, misalnya hingga 29.128.577 parameter, sehingga pelatihan dan inferensi menjadi sangat mahal secara komputasi. [A Deep Learning Network for Cloud-to-Ground Lightning.pdf] Volume data yang besar dikombinasikan dengan kebutuhan akurasi tinggi membatasi penerapan model klasik skala penuh, dan hal ini membuka peluang bagi quantum machine learning (QML) yang menjanjikan pemrosesan data besar secara paralel dengan kecepatan dan presisi yang lebih baik. [Assessment of Quantum ML Applicability for Climate Actions.pdf]

Selain itu, atmosfer digambarkan sebagai sistem dinamis dan kacau (dynamic and chaotic system), di mana variasi kecil pada kondisi awal dapat menyebabkan perubahan signifikan pada kondisi di masa depan. [Exploring Quantum Machine Learning for Weather Forecasting.pdf] Sifat chaotic dan kompleksitas non-linear ini menyulitkan model klasik untuk memberikan prediksi yang akurat, terutama pada rentang waktu lebih panjang atau untuk peristiwa ekstrem seperti GFD tinggi. [Exploring Quantum Machine Learning for Weather Forecasting.pdf] Meskipun CNN dan LSTM mampu memodelkan sistem non-linear yang kompleks, generalisasi terhadap data yang tidak seimbang atau jarang terjadi, seperti sambaran petir ekstrem, tetap menjadi tantangan nyata bagi deep learning klasik. [Exploring Quantum Machine Learning for Weather Forecasting.pdf]

Studi lain menunjukkan bahwa ketika badai petir disimulasikan pada skala yang lebih kecil dengan resolusi spasial dan temporal yang lebih halus, prediktabilitas kejadiannya justru berkurang. [A machine-learning approach to thunderstorm forecasting.pdf] Akurasi prediksi cenderung menurun seiring dengan peningkatan resolusi karena ketidakpastian prakiraan numerik (NWP) yang meningkat, sehingga terdapat batas fisik pada prediktabilitas sistem atmosfer. [A machine-learning ap-

proach to thunderstorm forecasting.pdf] Dalam konteks ini, QML diharapkan dapat mengimbangi peningkatan ketidakpastian melalui keunggulan komputasi dan representasi ruang fitur berdimensi tinggi. [Assessment of Quantum ML Applicability for Climate Actions.pdf]

II.3 Landasan Teori Komputasi Kuantum

II.3.1 Qubit dan Ruang Hilbert

Elemen dasar dari komputer kuantum adalah qubit, yang memiliki definisi matematis yang tepat sebagai unsur dalam suatu Ruang Hilbert kompleks. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] Ruang Hilbert tersebut merupakan ruang vektor berdimensi kompleks yang dilengkapi dengan inner product, di mana vektor-vektor di dalamnya memiliki amplitudo kompleks. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] Dalam konteks komputasi kuantum, qubit direpresentasikan sebagai vektor dalam Ruang Hilbert kompleks dua dimensi, dinotasikan sebagai RUMUS . [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] Qubit dijelaskan sebagai kombinasi linear dari basis komputasional, meskipun bentuk eksplisit basis tersebut tidak disajikan secara lengkap dalam kutipan. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] [KURANG INFORMASI MENGENAI bentuk eksplisit representasi vektor qubit dalam basis komputasional]

Keunggulan utama komputer kuantum berasal dari kemampuan untuk “meng-entangle” qubit, sehingga membentuk keadaan multi-qubit melalui tensor product dari vektor-vektor di Ruang Hilbert. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] Keadaan n-qubit dapat dituliskan sebagai kombinasi linear dari RUMUS basis state, sehingga secara efektif diasosiasikan dengan RUMUS bilangan kompleks yang menggambarkan amplitudo setiap basis. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] Peningkatan dimensi Ruang Hilbert yang berskala eksponensial terhadap jumlah qubit ini memiliki konsekuensi yang penting, karena memungkinkan representasi informasi dalam jumlah sangat besar secara intrinsik paralel. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf] Entanglement dapat diciptakan melalui operasi seperti Controlled-NOT (CNOT), sehingga qubit-kuubit secara kolektif dapat merepresentasikan struktur data kompleks yang relevan, misalnya data cuaca. [Quantum Computers for Weather and Climate Prediction The Good, the Bad and the Noisy.pdf]

Proses pengukuran dalam mekanika kuantum diatur oleh Aturan Born, yang menyatakan bahwa probabilitas mengamati suatu keluaran tertentu saat mengukur keadaan kuantum diberikan oleh ekspresi matematis tertentu yang tidak dicantumkan secara lengkap dalam kutipan. [Quantummachinelearning.pdf] Pengukuran merupakan proses non-reversibel yang menyebabkan keadaan superposisi kolaps menjadi salah satu status dasar. [Quantummachinelearning.pdf] [KURANG INFORMASI MENGENAI bentuk matematis lengkap Aturan Born yang digunakan]

II.3.2 Quantum Data Encoding/Feature Map

Feature map merupakan komponen fundamental dalam sirkuit QNN karena berfungsi memetakan input klasik ke dalam ruang kuantum yang didefinisikan di dalam Ruang Hilbert yang sangat kompleks. [Application of Quantum Neural Network.pdf] Tahap ini dianggap sebagai bagian paling kritis dalam desain QML karena mentransformasikan struktur data secara mendalam dan non-linear dengan cara yang tidak dapat dicapai oleh metode klasik. [Application of Quantum Neural Network.pdf] Dengan memproyeksikan data GFD tropis dan subtropis ke ruang fitur kuantum berdimensi tinggi, relasi non-linear antara variabel meteorologis dapat dieksplorasi dan diekstraksi secara lebih efisien dibandingkan pendekatan kernel klasik. [Application of Quantum Neural Network.pdf]

Salah satu metode encoding yang umum dan praktis untuk perangkat NISQ adalah angle embedding atau angle encoding. [Quantum machine learning early.pdf] Metode ini meng-encode vektor d-dimensi RUMUS ke dalam sudut rotasi gerbang qubit tunggal, sehingga untuk RUMUS $n \approx d$ qubit diperoleh operator RUMUS dengan RUMUS $P \square X, Y, Z$. [Quantum machine learning early.pdf] Pada konteks GFD, nilai fitur seperti CAPE atau kelembaban dapat dimasukkan langsung sebagai parameter sudut rotasi pada gerbang Pauli RUMUS. [Application of Quantum Neural Network.pdf] Hal ini mengimplikasikan bahwa setiap variabel input atmosfer memerlukan setidaknya satu qubit tersendiri, sehingga jumlah fitur input dibatasi oleh jumlah qubit yang tersedia pada perangkat NISQ. [Application of Quantum Neural Network.pdf]

Metode lain adalah amplitude embedding, yang meng-encode vektor fitur berdimensi N yang ternormalisasi ke dalam amplitudo keadaan n -qubit dengan syarat RUMUS. [Quantum machine learning early.pdf] Pendekatan ini sangat efisien dari sisi jumlah qubit karena mampu memetakan hingga RUMUS fitur ke dalam n qubit, tetapi implementasi fisiknya pada perangkat NISQ dianggap menantang. [Quantum machine learning early.pdf] Walaupun menawarkan efisiensi qubit yang superior,

keterbatasan implementasi ini menjadikan amplitude encoding kurang praktis untuk model GFD pada era NISQ dibandingkan angle encoding atau pendekatan encoding lain di ruang laten yang lebih sesuai dengan hardware saat ini. [Quantum machine learning early.pdf]

ZZ Feature Map merupakan contoh feature map yang lebih kompleks dan dapat diimplementasikan menggunakan Qiskit. [Application of Quantum Neural Network.pdf] Map ini tidak hanya meng-encode data, tetapi juga secara eksplisit memanfaatkan gerbang Hadamard dan CNOT untuk menciptakan entanglement dan mengkodekan interaksi antar fitur RUMUS melalui fase kuantum. [Application of Quantum Neural Network.pdf] Pendekatan ini sangat relevan untuk GFD karena interaksi non-linear antara variabel meteorologis, seperti CAPE dan kelembaban, berperan penting terhadap akurasi prediksi. [Application of Quantum Neural Network.pdf] [KURANG INFORMASI MENGENAI bentuk lengkap sirkuit ZZ feature map]

II.4 Arsitektur Model Kuantum

II.4.1 Variational Quantum Circuits (VQC)

Variational Quantum Circuits (VQC), yang juga dikenal sebagai Variational Quantum Algorithms (VQA) atau Quantum Neural Networks (QNN), merupakan strategi utama untuk mencapai keunggulan komputasi kuantum menggunakan perangkat NISQ (Noisy Intermediate-Scale Quantum). [Variational quantum algorithms.pdf] VQA memanfaatkan classical optimizer untuk melatih sirkuit kuantum berparameter (parameterized quantum circuit), sehingga membentuk kerangka kerja hybrid kuantum-klasik. [Variational quantum algorithms.pdf]

Secara arsitektural, model QNN terdiri dari tiga komponen dasar, yaitu Feature Map, Ansatz, dan Measurement, yang bersama-sama membentuk sirkuit kuantum tempat data diproses. [Application of Quantum Neural Network.pdf] Kerangka EstimatorQNN pada Qiskit memanfaatkan sirkuit kuantum campuran yang terdiri dari dua komponen terpisah: feature map dan ansatz. [Application of Quantum Neural Network.pdf] Dalam konteks tesis ini, Feature Map digunakan untuk meng-encode data meteorologis, Ansatz untuk memproses dan melatih parameter kuantum, dan Measurement untuk memperoleh keluaran prediksi GFD. [Application of Quantum Neural Network.pdf]

Ansatz dalam QNN merujuk pada tebakan awal untuk suatu keadaan kuantum, yang

berperan sebagai titik awal perhitungan. [Application of Quantum Neural Network.pdf] Dalam analogi dengan machine learning klasik, ansatz berperan seperti bobot pelatihan, di mana sirkuit kuantum berparameter ini dioptimalkan untuk meminimalkan fungsi biaya tertentu. [Application of Quantum Neural Network.pdf] Parameter dalam ansatz (misalnya sudut rotasi θ) dilatih pada setiap iterasi menggunakan algoritma optimasi klasik yang dijalankan pada komputer klasik, sehingga membentuk hybrid loop VQC. [Application of Quantum Neural Network.pdf]

Beberapa jenis ansatz yang umum digunakan pada framework Qiskit antara lain TwoLocal ansatz dan Ry ansatz. [Application of Quantum Neural Network.pdf] TwoLocal ansatz terdiri atas lapisan-lapisan rotasi dan entanglement dengan gerbang berparameter, di mana gerbang rotasi diterapkan pada setiap qubit secara individual, sedangkan entanglement diterapkan pada dua qubit sesuai strategi entanglement yang diinginkan. [Application of Quantum Neural Network.pdf] Ry ansatz memanfaatkan gerbang Pauli-Y berparameter sebagai blok rotasi, sedangkan QAOA (Quantum Approximate Optimization Algorithm) digunakan sebagai ansatz yang merupakan kasus khusus dari VQE (Variational Quantum Eigensolver). [Application of Quantum Neural Network.pdf] Ansatz-ansatz ini relevan untuk merancang arsitektur VQC dalam tugas prediksi GFD. [Application of Quantum Neural Network.pdf]

II.4.2 QNN vs. QSVM

Prediksi GFD merupakan tugas regresi karena GFD berupa nilai kontinu, sehingga perbandingan antara QNN/VQR (Variational Quantum Regressor) dan QSVM (Quantum Support Vector Regressor) menjadi penting. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf] Sebuah studi peramalan deret waktu suhu permukaan global yang membandingkan berbagai pendekatan, termasuk ARMA, ARIMA, SARIMA, LSTM, CNN-LSTM, ConvLSTM, dan teknik QML seperti QNN, VQR, dan QSVM, menemukan bahwa QSVM menjadi model yang menonjol untuk time-series forecasting. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf] Keunggulan QSVM tersebut dikaitkan dengan kemampuannya memanfaatkan quantum kernels untuk menangkap pola non-linear dalam data iklim. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf]

Di sisi lain, QNN dipandang sebagai frontier baru di bidang komputasi kuantum yang memutuskan diri dari struktur jaringan saraf tradisional sambil mempertahankan prinsip-prinsip fundamentalnya. [The power of quantum neural networks.pdf]

Tidak seperti jaringan saraf klasik, QNN tidak memiliki neuron kuantum diskrit, dan keluaran model diekstraksi melalui fungsi post-processing klasik yang diterapkan pada hasil pengukuran (measurement outcome) dari sirkuit kuantum. [The power of quantum neural networks.pdf] Dalam konteks regresi GFD, nilai prediksi kontinu dapat diperoleh dari nilai ekspektasi suatu operator (observable) pada qubit keluaran, kemudian diolah lebih lanjut dengan fungsi klasik. [Solving nonlinear differential equations....pdf]

Dari sisi kompleksitas komputasi, pelatihan QSVR memerlukan perhitungan jarak pasangan (pair-wise distances) antara seluruh sampel pelatihan dalam matriks Gram berukuran RUMUS $M \times M$, sehingga kompleksitas waktunya paling tidak RUMUS) terhadap jumlah sampel pelatihan M . [Supervised quantum machine learning models....pdf] Sebaliknya, pelatihan jaringan saraf, termasuk QNN/VQR yang dioptimalkan dengan pendekatan gradient-based, memiliki kompleksitas waktu RUMUS $O(M)$ yang bergantung secara linear pada jumlah sampel pelatihan. [Supervised quantum machine learning models....pdf] [KURANG INFORMASI MENGENAI orde kompleksitas waktu pelatihan QNN secara eksplisit di luar pernyataan umum RUMUS

Studi lain menunjukkan bahwa QNN mampu mencapai effective dimension yang secara signifikan lebih baik dibandingkan jaringan saraf klasik yang sebanding, yang dikaitkan dengan lanskap optimasi yang lebih menguntungkan dan spektrum Fisher information yang lebih merata. [The power of quantum neural networks.pdf] Daya ekspresif (expressibility) yang lebih tinggi ini menjadikan QNN kandidat potensial untuk memodelkan dinamika GFD yang sangat non-linear dan chaotic, terutama ketika kompleksitas data menuntut ansatz yang lebih dalam dengan banyak lapisan. [The power of quantum neural networks.pdf]

II.5 Implementasi pada Framework Qiskit

II.5.1 Komponen Ekosistem Qiskit

Qiskit merupakan software development kit open-source untuk quantum information science yang dikembangkan dengan arsitektur berbasis sirkuit. [Qiskit: An Open-source Framework for Quantum Computing.pdf] Kerangka kerja ini bertumpu pada tiga komponen utama, yaitu circuits, pass managers, dan primitives. [Qiskit: An Open-source Framework for Quantum Computing.pdf] Pass managers digunakan untuk mengoptimasi sirkuit kuantum, sedangkan primitives menyediakan antarmuka standar untuk mengevaluasi sirkuit pada perangkat kuantum, sehingga es-

ensial dalam melatih model QNN. [Dancing with Qubits.pdf]

Dalam komputasi kuantum, terdapat dua primitives utama untuk menangkap keluaran sirkuit kuantum, yakni sampling output bitstrings dan estimasi observable expectation values. [Quantum computing with Qiskit.pdf] Primitives diimplementasikan sebagai sampler dan estimator, di mana EstimatorQNN memanfaatkan BaseEstimator primitive dari Qiskit untuk mengintegrasikan sirkuit kuantum berparameter dengan observables mekanika kuantum. [Quantum computing with Qiskit.pdf] Dalam konteks prediksi GFD, estimator digunakan untuk mengukur nilai ekspektasi operator seperti Pauli RUMUS X, yang kemudian menjadi keluaran prediksi seperti probabilitas GFD tinggi. [Assessment of Quantum ML Applicability for Climate Actions...pdf]

Qiskit dirancang sebagai kerangka kerja ringan yang dapat diintegrasikan ke dalam lingkungan runtime yang mengkolokasikan prosesor kuantum dengan prosesor klasik umum, sehingga ribuan sirkuit dapat dihasilkan dan dievaluasi secara dinamis untuk memperoleh solusi akhir. [Quantum computing with Qiskit.pdf] Contoh lingkungan runtime ini adalah Qiskit Runtime yang diimplementasikan pada komputer kuantum IBM, yang memungkinkan algoritma hybrid seperti QNN/VQR dioptimalkan secara efisien melalui interaksi intensif antara optimizer klasik (misalnya COBYLA atau Adam) dan prosesor kuantum yang mengeksekusi sirkuit dan mengukur primitives. [Quantum machine learning early.pdf]

II.5.2 Penanganan Noise pada Era NISQ

Perangkat kuantum saat ini beroperasi pada era NISQ (noisy intermediate-scale quantum), yang dicirikan oleh jumlah qubit yang terbatas (puluhan hingga beberapa ratus) dan kerentanan terhadap error akibat noise lingkungan dan ketidaksem-purnaan kontrol. [Quantum machine learning early.pdf] Qubit pada era ini memiliki waktu koherensi yang pendek, sehingga sirkuit kuantum harus dirancang dengan kedalaman yang dangkal (shallow depth) agar hasil pengukuran tetap valid. [Variational quantum algorithms.pdf] Kondisi ini menjadi motivasi utama penggunaan strategi VQA/VQC dalam tesis ini karena algoritma variational dirancang khusus untuk beroperasi pada perangkat NISQ. [Application of Quantum Neural Network.pdf]

Dalam jangka panjang, tujuan utama bidang komputasi kuantum adalah mengimplementasikan Quantum Error Correction (QEC), namun QEC merupakan tantangan rekayasa kuantum tingkat lanjut yang membutuhkan ribuan qubit fisik un-

tuk mewujudkan satu qubit logis yang bebas noise, sehingga belum praktis pada perangkat sekarang. [Dancing with Qubits.pdf] Untuk era NISQ, pendekatan yang lebih realistik adalah error mitigation (EM) berbasis perangkat lunak, yang digunakan untuk mengestimasi hasil bebas noise dari keluaran yang bising. [Quantum machine learning early.pdf] Metode-metode EM dapat digabungkan dengan VQA untuk meningkatkan akurasi hasil, misalnya ketika model dijalankan pada perangkat nyata seperti IBM 127-qubit Eagle. [Assessment of Quantum ML Applicability for Climate Actions...pdf]

Salah satu teknik EM yang menonjol adalah zero-noise extrapolation (ZNE). [Variational quantum algorithms.pdf] Teknik ini memanfaatkan fakta bahwa meskipun laju error tidak dapat dikurangi, dalam banyak kasus noise dapat sengaja ditingkatkan; dengan menjalankan sirkuit pada beberapa tingkat noise yang berbeda dan mengumpulkan hasil pengukuran, kemudian dilakukan proses ekstrapolasi untuk mengestimasi hasil pada batas noise nol. [Quantum computing with Qiskit.pdf] Pendekatan ZNE ini melibatkan post-processing klasik terhadap hasil pengukuran dan digunakan untuk meningkatkan akurasi nilai ekspektasi yang dihitung oleh estimator. [Variational quantum algorithms.pdf]

II.6 Tinjauan Penelitian Terdahulu dan Gap Analisis

II.6.1 Review Penelitian Terdahulu (QML in Meteorology)

Penelitian QML dalam meteorologi dan environmental forecasting telah menunjukkan potensi signifikan, terutama dalam menangani data deret waktu dan kompleksitas non-linear yang tinggi. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf] Sebagian besar studi awal QML berfokus pada prediksi energi (seperti kecepatan angin dan iradiasi matahari) serta klasifikasi iklim, karena data tersebut memiliki karakteristik time-series yang mirip dengan data GFD. [Exploring Quantum Machine Learning for Weather Forecasting.pdf]

Sebuah studi membandingkan berbagai pendekatan untuk memprediksi suhu permukaan global termasuk metode classical machine learning seperti ARMA, ARIMA, dan SARIMA, jaringan saraf seperti LSTM, CNN-LSTM, dan ConvLSTM, serta teknik QML seperti QNN, VQR, dan QSVR. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf] Hasilnya menunjukkan bahwa QSVR menjadi model unggulan untuk time-series forecasting karena kemampuannya memanfaatkan quantum kernels dalam menangkap pola non-linear

pada data iklim. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf] Hal ini memvalidasi premis bahwa teknik QML berpotensi mengungguli model DL klasik untuk tugas regresi iklim yang kompleks, termasuk prediksi GFD. [A comparative analysis of classical machine learning models with quantum-inspired models....pdf]

Penelitian lain yang mengimplementasikan QNN menggunakan Qiskit untuk memvalidkan global horizontal irradiance (GHI) menunjukkan bahwa QNN mampu memberikan hasil yang kompetitif untuk horizon peramalan 5 hingga 120 menit dan bahkan mengungguli pendekatan klasik seperti SVR dan GMDH pada horizon 180 menit. [Application of Quantum Neural Network.pdf] Hal ini menunjukkan kapasitas QNN dalam mengidentifikasi dan mengekstrak informasi spatiotemporal dari data, serta potensi keunggulannya pada horizon peramalan yang lebih panjang, yang relevan untuk sistem peringatan dini bencana terkait GFD tinggi. [Application of Quantum Neural Network.pdf]

Pada prediksi kecepatan angin, yang juga dipandang sebagai fenomena atmosfer yang sangat chaotic, QNN menunjukkan potensi untuk mengungguli Recurrent Neural Network (RNN) klasik dalam hal akurasi dan kemampuan beradaptasi terhadap perubahan data yang mendadak. [Exploring Quantum Machine Learning for Weather Forecasting.pdf] Kemampuan QNN untuk lebih tahan terhadap data yang sangat bervariasi dan noisy ini sangat relevan untuk prediksi GFD di wilayah tropis yang dikenal memiliki variabilitas tinggi. [Exploring Quantum Machine Learning for Weather Forecasting.pdf]

Studi lain mengevaluasi berbagai classifier termasuk SVM klasik, QSVC, dan VQC pada simulator kuantum IBM dan komputer kuantum IBM 127-qubit menggunakan data iklim dan cuaca Earth Observation dari NASA bersama pustaka Qiskit ML 0.7.2. [Assessment of Quantum ML Applicability for Climate Actions...pdf] Hasilnya menunjukkan bahwa dua model kuantum (QSVC dan VQC) mampu memprediksi label kelas dengan kualitas yang wajar hanya dengan menggunakan dua qubit, yang menegaskan kelayakan teknis penerapan QML berbasis Qiskit dengan data satelit untuk aplikasi iklim dan cuaca. [Assessment of Quantum ML Applicability for Climate Actions...pdf]

Dalam konteks cuaca ekstrem, studi lain melaporkan bahwa model kuantum mampu meningkatkan akurasi prediksi hingga 92 persen untuk badai tropis dan sekali-gus mempercepat waktu komputasi dari 48 jam menjadi 5 jam dibandingkan model konvensional. [Quantum Computing to Forecast Extreme Weather.pdf] Temuan

ini menguatkan hipotesis bahwa QNN memiliki keunggulan komputasi yang relevan untuk memprediksi fenomena cuaca ekstrem, termasuk GFD tinggi. [Quantum Computing to Forecast Extreme Weather.pdf]

II.6.2 Identifikasi Gap Penelitian

Dari perspektif geografis dan standar rekayasa, standar proteksi petir internasional seperti IEC, NFPA, IEEE, JIS, dan NEMA saat ini dikembangkan terutama berdasarkan karakteristik petir subtropis. [Review of NFPA 780 Standard Compliance for Improved.pdf] Hal ini menimbulkan ketidaksesuaian ketika standar tersebut diterapkan di wilayah tropis, sehingga mendorong Indonesia untuk mengembangkan bidang penelitian dan lokasi uji seperti Stasiun Penelitian Petir Gunung Tangkuban Perahu (SPP-TP) dan lokasi di Bogor (SPP-Bogor) untuk mengkaji dan menginovasi sistem proteksi petir tropis. [Review of NFPA 780 Standard Compliance for Improved.pdf]

Sebagaimana telah dijelaskan, terdapat disparitas signifikan antara perilaku petir di iklim tropis dan subtropis, dan investigasi selama delapan tahun di SPP-TP mengungkap berbagai atribut unik petir tropis. [A Method to Obtain Lightning Peak Current in Indonesia.pdf] Perbedaan ini menimbulkan kebutuhan akan model prediksi yang adaptif secara regional, yang tidak dapat dipenuhi oleh model QML yang dikembangkan hanya berdasarkan data iklim Amerika Utara atau Eropa yang umumnya beriklim subtropis atau lintang menengah. [Review of NFPA 780 Standard Compliance for Improved.pdf]

Dari perspektif metodologis, aplikasi ML yang memanfaatkan data EO untuk memprediksi fenomena iklim memang sudah ada, namun kemampuan model-model tersebut untuk beradaptasi dari satu wilayah ke wilayah lain masih belum banyak dieksplorasi. [Assessment of Quantum ML Applicability for Climate Actions...pdf] Kesenjangan ini memperkuat urgensi penelitian yang tidak hanya mengembangkan QNN, tetapi juga menguji kemampuan generalisasi dan adaptasinya terhadap dua rezim iklim berbeda (tropis vs. subtropis) yang memiliki karakteristik lightning flash yang berlainan. [Assessment of Quantum ML Applicability for Climate Actions...pdf]

Selain kesenjangan geografis, terdapat pula kesenjangan teknis terkait hardware kuantum yang masih dalam tahap pengembangan, sehingga membatasi aplikasi praktis dalam skala besar. [Quantum Computing to Forecast Extreme Weather.pdf] Studi tersebut menekankan bahwa penelitian lanjutan diperlukan untuk mengembangkan sistem kuantum yang lebih stabil dan andal agar mampu memproses data cuaca yang

lebih kompleks. [Quantum Computing to Forecast Extreme Weather.pdf] Tesis ini diharapkan berkontribusi dengan menunjukkan bagaimana QNN dapat mencapai keunggulan komputasi dalam memodelkan interaksi variabel GFD tropis meskipun menggunakan sirkuit kuantum dangkal yang sesuai dengan keterbatasan perangkat NISQ dan ekosistem Qiskit saat ini. [Quantum Computing to Forecast Extreme Weather.pdf]

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Prediksi GFD dan parameter petir saat ini didominasi model numerik dan ML klasik NWP dan parameterisasi petir berbasis rumus fisik masih terbatas dalam menangkap proses multi-skala dan sifat chaotic atmosfer. Algoritma klasik (DT, RF, SVM, ANN) sangat bergantung pada feature engineering manual dan sering kesulitan memodelkan interaksi non-linear antar variabel meteorologis.

Pendekatan deep learning (CNN/LSTM/ConvLSTM) sudah digunakan untuk nowcasting petir

Arsitektur kompleks (misalnya encoder-decoder 3D CNN, ConvLSTM) dapat memproses data satelit/radar multi-dimensi tetapi memiliki puluhan juta parameter yang mahal secara komputasi. Biaya pelatihan dan inferensi tinggi membatasi penerapan operasional, terutama jika ingin melakukan eksperimen multi-skenario atau studi generalisasi lintas wilayah.

Keterbatasan generalisasi model klasik dan deep learning

Atmosfer bersifat dinamis dan chaotic; perubahan kecil pada kondisi awal dapat memicu perbedaan besar pada output, sehingga akurasi model klasik mudah turun di luar domain data latih. Peristiwa ekstrem seperti GFD tinggi relatif jarang, sehingga model cenderung bias ke kondisi normal dan kurang akurat untuk ekor distribusi (tail events).

Konteks Indonesia/tropis vs subtropis belum terakomodasi dengan baik
Indonesia memiliki awan CB yang lebih lebar, long tail wave pada arus petir, dan

densitas sambaran ke tanah yang lebih tinggi dibanding wilayah subtropis. Standar proteksi petir (IEC, NFPA, dll.) banyak dibangun dari data subtropis/lintang menengah, sehingga berpotensi tidak sepenuhnya sesuai jika langsung diterapkan pada iklim tropis maritim Indonesia.

Keterpisahan sumber data global dan lokal

Data satelit global (LIS/OTD) memberikan climatology GFD resolusi global, sedangkan data lokal (mis. PLN) merekam sambaran aktual di jaringan tenaga listrik. Integrasi dan pemodelan bersama kedua sumber (tropis vs subtropis) untuk menghasilkan model GFD adaptif secara regional masih minim.

Posisi terkini komputasi kuantum dan QML

QML telah dicoba untuk prediksi suhu permukaan, kecepatan angin, iradiasi matahari, dan GHI dengan hasil yang kompetitif, namun belum ada studi spesifik untuk GFD petir. Perangkat masih berada di era NISQ, sehingga banyak penelitian bergantung pada simulator dan perangkat IBM Quantum ukuran kecil dengan sirkuit dan gkal.

III.2 Analisis Kebutuhan

...

III.2.1 Identifikasi Masalah Pengguna

Insinyur proteksi petir dan perencana sistem tenaga (mis. PLN)

Membutuhkan estimasi GFD yang reliabel per lokasi untuk menghitung risiko dan merancang sistem proteksi (tower, gardu, jaringan transmisi/distribusi) secara ekonomis namun aman. Menghadapi ketidakpastian karena peta GFD berbasis subtropis mungkin tidak cocok dengan karakteristik petir tropis Indonesia.

Peneliti meteorologi dan klimatologi petir

Memerlukan model yang mampu mengeksplorasi hubungan non-linear antara variabel meteorologis (CAPE, presipitasi, kelembapan, dll.) dengan GFD, termasuk perbedaan tropis vs subtropis. Kesulitan mengevaluasi apakah model yang terlatih di suatu rezim iklim dapat digeneralisasi ke rezim lain tanpa kehilangan akurasi secara drastis.

Penyusun standar dan regulator

Perlu evidensi ilmiah berbasis data untuk meninjau kecocokan standar proteksi petir yang bersumber dari data subtropis ketika diterapkan di Indonesia dan wilayah tropis lainnya. Memerlukan indikator kuantitatif yang menunjukkan gap antara GFD “standar” vs GFD aktual tropis.

Komunitas QML dan komputasi kuantum terapan

Membutuhkan studi kasus konkret di domein meteorologi tropis untuk mengevaluasi benefit praktis QNN/VQC dibanding model klasik. Menghadapi keterbatasan contoh implementasi end-to-end yang menghubungkan data cuaca/petir dunia nyata dengan arsitektur QNN di Qiskit.

Masalah praktis lintas pemangku kepentingan

Ketidakakuratan GFD mengarah pada desain proteksi over-designed (mahal) atau under-designed (tidak aman). Keterbatasan model yang tidak generalizable menyulitkan transfer pengetahuan dari wilayah subtropis ke tropis dan sebaliknya.

III.2.2 Kebutuhan Fungsional

Model prediksi GFD kontinu berbasis QNN/VQC

Menerima input berupa fitur meteorologis dan/atau klimatologis yang relevan (mis. CAPE, presipitasi, suhu permukaan, kelembapan, variabel geopotensial, dsb.). Menghasilkan output berupa estimasi nilai GFD (mis. sambaran per km² per tahun) untuk suatu grid/wilayah.

Kemampuan membedakan dan memodelkan pola tropis vs subtropis

Mengakomodasi penandaan domain (tropis/subtropis) atau koordinat geografis sebagai bagian dari fitur. Mampu mempelajari perbedaan pola GFD pada kedua rezim iklim dan memvisualisasikannya melalui analisis error dan distribusi prediksi.

Dukungan eksperimen generalisasi lintas domain

Memungkinkan skenario train-on-tropics, test-on-subtropics dan sebaliknya untuk mengukur kemampuan adaptasi model. Menyediakan pipeline untuk membandingkan performa cross-domain vs in-domain menggunakan metrik yang sama.

Integrasi dengan baseline klasik

Menyertakan implementasi model klasik (mis. RF, SVR, MLP sederhana, atau DL ringan) pada dataset yang sama sebagai pembanding kinerja. Menyediakan fungsi evaluasi bersama (common evaluation interface) antara QNN dan baseline klasik.

Manajemen eksperimen dan konfigurasi

Menyimpan konfigurasi feature map, ansatz, optimizer, dan hyperparameter lain dalam bentuk yang dapat direplikasi. Menyediakan fungsi untuk menyimpan dan memanggil kembali model/predictor yang telah terlatih untuk keperluan analisis dan validasi lanjutan.

III.2.3 Kebutuhan Nonfungsional

Keterbatasan komputasi dan hardware

Implementasi utama menggunakan simulator Qiskit pada komputer pribadi, sehingga jumlah qubit dan kedalaman sirkuit harus dibatasi. Waktu pelatihan dan inferensi harus tetap dalam rentang yang wajar untuk ukuran dataset yang tersedia, sehingga arsitektur QNN perlu efisien.

Kualitas dan kelengkapan dataset

Data PLN dan NASA/LIS-OTD mungkin memiliki cakupan temporal/spasial yang berbeda, missing values, dan ketidakseimbangan distribusi GFD. Diperlukan prosedur preprocessing dan pembersihan data yang jelas untuk mengurangi bias dan noise.

Interpretabilitas dan transparansi minimal

Walaupun QNN bersifat black-box, hasil perlu dilengkapi dengan analisis metrik (MSE, RMSE, MAE, R²) dan visualisasi sederhana (mis. plot aktual vs prediksi, sebar error). Dokumentasi pemilihan fitur dan justifikasi desain arsitektur (feature map, ansatz) harus jelas.

Reproducibility dan maintainability

Kode, konfigurasi eksperimen, dan versi pustaka (Python, Qiskit) perlu dicatat untuk mendukung replikasi hasil di masa depan. Struktur proyek (notebook, modul Python) harus rapi untuk memudahkan pengembangan lanjutan oleh peneliti lain.

Kesesuaian dengan batasan era NISQ

Arsitektur QNN harus mempertimbangkan noise dan batas kedalaman sirkuit jika

kelak dijalankan di perangkat IBM Quantum nyata. Desain perlu kompatibel dengan teknik error mitigation sederhana yang tersedia di Qiskit.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Pendekatan ML klasik murni

Menggunakan RF, SVR, gradient boosting, atau MLP untuk memprediksi GFD dari fitur meteorologis. Kelebihan: tooling matang, implementasi sederhana, kebutuhan komputasi diketahui.

Pendekatan deep learning spatiotemporal

Mengadopsi CNN, LSTM, atau ConvLSTM yang telah digunakan di penelitian now-casting petir dan cuaca. Kelebihan: mampu menangkap pola spasial-temporal kompleks, tetapi memerlukan data besar dan komputasi berat.

Hybrid klasik dengan feature engineering intensif

Menggabungkan transformasi fitur (mis. PCA, statistik klimatologis) dengan model klasik (RF/SVR). Mengandalkan kreativitas feature design untuk menangkap non-linearitas dan perbedaan tropis vs subtropis.

QML berbasis QSvr (quantum kernel method)

Menggunakan QSvr dengan quantum feature map untuk membangun kernel non-linear di ruang Hilbert. Potensial unggul dalam time-series forecasting, namun training membutuhkan komputasi matriks Gram $M \times M$ yang mahal untuk M sampel besar.

QML berbasis QNN/VQC

Menggunakan arsitektur VQC dengan EstimatorQNN sebagai regressor GFD. Memanfaatkan hybrid loop klasik-kuantum untuk melatih parameter ansatz secara iteratif.

III.3.2 Analisis Penentuan Solusi

Kesesuaian dengan tujuan penelitian

Tujuan utama adalah mengeksplorasi potensi QML, khususnya QNN/VQC di Qiskit, untuk prediksi GFD tropis dan subtropis, bukan sekadar memaksimalkan akurasi dengan model klasik. QNN menyediakan kerangka yang lebih kaya untuk mengkaji expressibility dan effective dimension dibanding QSVR semata.

Pertimbangan kompleksitas komputasi

QSVR berbasis kernel memerlukan perhitungan Gram matrix berukuran $M \times M$ yang berskala minimal $O(M^2 - M^3)$, sehingga kurang efisien untuk jumlah sampel latih menengah. Training QNN/VQC dengan optimizer berbasis gradient atau heuristic cenderung menskala linier terhadap jumlah sampel, lebih sesuai untuk eksperimen pada dataset GFD ukuran menengah.

Kesesuaian dengan era NISQ dan ekosistem Qiskit

VQC dirancang untuk perangkat NISQ dengan kedalaman sirkuit yang dapat dikontrol, serta mudah dioptimasi dengan classical optimizer. Qiskit menyediakan primitive Estimator, library feature map (mis. ZZFeatureMap), dan ansatz (TwoLocal, Ry, dsb.) yang langsung dapat dimanfaatkan.

Fleksibilitas arsitektur dan desain eksperimen

QNN memungkinkan eksplorasi berbagai kombinasi feature map–ansatz dan kedalaman sirkuit untuk menyesuaikan dengan kompleksitas data dan keterbatasan komputasi. Arsitektur yang sama dapat diadaptasi untuk studi generalisasi tropis vs subtropis dengan mengganti skema input atau konfigurasi training.

Nilai tambah ilmiah dibanding baseline klasik

Dengan tetap menyertakan baseline klasik, pemilihan QNN/VQC memberikan kontribusi ilmiah berupa perbandingan sistematis antara dua paradigma komputasi pada kasus GFD. Hasil eksperimen dapat menjadi acuan awal bagi pengembangan standar dan aplikasi QML lebih lanjut di bidang meteorologi tropis.

Peluang implementasi di hardware kuantum nyata

Desain VQC yang dangkal dan hemat qubit membuka peluang untuk uji coba di perangkat IBM Quantum ketika sumber daya tersedia. Hal ini memberikan nilai demonstrasi praktis yang tidak dapat diperoleh jika hanya mengandalkan model klasik.

BAB IV

DESAIN KONSEP SOLUSI

Arsitektur umum solusi usulan (gambaran end-to-end)

Input: kumpulan data petir dan meteorologi dari PLN (wilayah tropis) dan NASA/LIS-OTD (global/subtropis) yang telah dipilih sesuai ruang lingkup penelitian. Modul preprocessing: pembersihan data, rekonsiliasi format, agregasi spasial-temporal, perhitungan GFD, dan konstruksi fitur meteorologis. Modul pemodelan klasik: implementasi baseline (mis. RF/SVR/MLP) untuk memprediksi GFD dengan pipeline yang serupa. Modul QNN/VQC berbasis Qiskit: encoding data ke ruang kuantum (feature map), pemrosesan melalui ansatz parametrik, dan measurement via EstimatorQNN untuk menghasilkan prediksi GFD. Modul evaluasi: perhitungan metrik (MSE, RMSE, MAE, R²), analisis error, dan visualisasi perbandingan tropis vs subtropis serta QNN vs model klasik.

Komponen utama sistem yang diusulkan

Sumber data:

Dataset sambaran petir lokal (mis. PLN) yang berisi lokasi dan waktu sambaran di wilayah tropis Indonesia. Dataset satelit NASA/LIS-OTD yang menyediakan informasi flashes dan/atau GFD di wilayah subtropis dan global.

Modul pengolahan data:

Sinkronisasi resolusi spasial (grid) dan temporal antara dataset; kalkulasi GFD per grid. Normalisasi dan scaling fitur sehingga sesuai untuk encoding kuantum (mis. rentang sudut rotasi).

Modul Qiskit (inti kuantum):

Feature map (mis. angle encoding atau ZZFeatureMap) untuk memetakan fitur meteorologis ke state qubit. Ansatz parametrik (mis. TwoLocal/Ry) yang membentuk VQC dengan kedalaman terkendali. Estimator primitive untuk menghitung expectation value sebagai output regresi GFD.

Modul evaluasi dan analisis:

Fungsi evaluasi terstandardisasi untuk semua model (klasik dan QNN). Fasilitas untuk membandingkan performa di domain tropis dan subtropis serta skenario cross-domain.

Sistem saat ini (before) – karakteristik umum

Peta GFD dan parameter petir banyak bergantung pada model numerik, statistik klimatologis, atau ML klasik yang dikembangkan di wilayah subtropis/lintang menengah. Integrasi eksplisit antara data tropis Indonesia (PLN) dan data global/subtropis (NASA/LIS-OTD) dalam satu kerangka pemodelan masih terbatas. Belum ada pemanfaatan QNN/VQC sebagai alternatif atau pelengkap model klasik untuk tugas prediksi GFD.

Sistem usulan (after) – konsep solusi QML untuk GFD

Mengintegrasikan data tropis dan subtropis dalam satu pipeline analitik, dengan penandaan domain yang jelas untuk studi generalisasi. Menyediakan dua jalur pemodelan: jalur klasik (baseline) dan jalur QNN/VQC di Qiskit, sehingga dapat dievaluasi berdampingan pada data dan metrik yang sama. Menghasilkan fungsi prediktor GFD berbasis QNN yang siap diuji untuk berbagai konfigurasi (in-domain vs cross-domain, variasi fitur, variasi ansatz). Membuka ruang untuk pengujian di perangkat kuantum nyata melalui desain sirkuit yang dangkal dan hemat qubit.

Alur data dan pemodelan (konsep block diagram)

Data mentah (PLN + NASA) → modul preprocessing integrasi → dataset fitur siap pakai (tropis, subtropis, label GFD). Dataset fitur → pembagian train/validation/test (dengan skenario domain-aware) →

Cabang 1: training model klasik (RF/SVR/MLP) + evaluasi baseline. Cabang 2: encoding data ke sirkuit QNN (feature map + ansatz) → training VQC dengan optimizer klasik → evaluasi QNN.

Hasil evaluasi → modul analisis (perbandingan model, analisis error, visualisasi

pola tropis vs subtropis) → rekomendasi dan insight untuk standar/proteksi petir.

Keterkaitan dengan metodologi (PRISMA, Concept Matrix, CRISP-DM)

PRISMA + Concept Matrix digunakan di awal untuk mengidentifikasi literatur terkait GFD, ML, dan QML, sehingga desain solusi merefleksikan gap yang telah dipetakan. CRISP-DM memandu alur: Business Understanding (urgensi GFD tropis), Data Understanding Preparation (integrasi PLN + NASA), Modeling (baseline klasik QNN), Evaluation (perbandingan metrik), hingga Deployment (formulasi predictor dan dokumentasi hasil).

BAB V

RENCANA SELANJUTNYA

V.1 Rencana Implementasi

Tahap persiapan dan pematangan studi literatur

Menyelesaikan studi literatur dengan protokol PRISMA dan Concept Matrix untuk memfinalisasi daftar variabel meteorologis dan arsitektur QNN yang paling relevan dengan GFD. Merumuskan lebih rinci skenario eksperimen (in-domain vs cross-domain, baseline vs QNN).

Pengumpulan dan integrasi data

Memperoleh dataset petir dari PLN (wilayah tropis Indonesia) dan data LIS/OTD atau produk NASA lain untuk wilayah subtropis/lintang menengah sesuai ruang lingkup. Melakukan rekonsiliasi format, sistem koordinat, dan resolusi spasial-temporal; menghitung nilai GFD per grid/wilayah sesuai definisi penelitian.

Preprocessing dan pemilihan fitur

Membersihkan data dari outlier, data ganda, dan missing values, serta menyesuaikan periode waktu yang overlap antara dataset. Memilih dan/atau membangun fitur meteorologis (CAPE, presipitasi, suhu, kelembapan, dsb.) berdasarkan literatur dan ketersediaan data, kemudian melakukan normalisasi/standarisasi.

Implementasi lingkungan pemodelan

Menyiapkan lingkungan Python, Jupyter Notebook, dan pustaka yang diperlukan (Qiskit, scikit-learn, pustaka numerik) di laptop penelitian. Mengonfigurasi akses ke IBM Quantum (jika memungkinkan) untuk uji coba terbatas di hardware nyata, dengan tetap menjadikan simulator sebagai platform utama.

Pembangunan dan pelatihan model

Mengimplementasikan baseline klasik (mis. RF, SVR, MLP sederhana) pada dataset GFD terintegrasi sesuai skenario train/test yang direncanakan. Mendesain dan mengimplementasikan QNN/VQC di Qiskit: memilih feature map dan ansatz, mengatur jumlah qubit, kedalaman sirkuit, optimizer, dan hyperparameter lain; kemudian melakukan training dan tuning bertahap.

Dokumentasi dan pengelolaan eksperimen

Mencatat semua konfigurasi, seed, dan hasil eksperimen dalam log/Spreadsheet untuk memudahkan analisis akhir. Menyusun struktur folder dan notebook yang terorganisir (data, preprocessing, baseline, QNN, evaluasi) sebagai dasar penulisan BAB hasil dan pembahasan.

V.2 Desain Pengujian dan Evaluasi

Strategi pembagian data dan skenario uji

Membagi data menjadi set train, validation, dan test dengan mempertimbangkan pemisahan domain (tropis vs subtropis) dan/atau jendela waktu tertentu. Menyusun beberapa skenario: Skenario in-domain (train dan test dalam domain yang sama). Skenario cross-domain (train tropis – test subtropis, dan sebaliknya).

Metrik evaluasi dan prosedur pengukuran

Menetapkan metrik utama seperti MSE, RMSE, MAE, dan R^2 untuk mengukur akurasi prediksi GFD. Menggunakan metrik yang sama untuk seluruh model (klasik dan QNN) agar perbandingan adil dan transparan.

Perbandingan dengan baseline klasik

Menghasilkan tabel dan grafik perbandingan kinerja baseline (RF/SVR/MLP) vs QNN pada setiap skenario (in-domain, cross-domain). Menganalisis kondisi di mana QNN memberikan perbaikan (atau penurunan) performa dibanding baseline, termasuk perbedaan perilaku pada GFD tinggi.

Evaluasi generalisasi tropis–subtropis

Mengkaji error distribusi per domain untuk melihat apakah model yang dilatih di satu domain tetap stabil ketika diuji di domain lain. Menginterpretasikan hasil gen-

eralisasi dalam konteks perbedaan karakteristik petir tropis vs subtropis dan implikasinya bagi desain proteksi.

Analisis sensitivitas dan ablation study sederhana

Mencoba variasi jumlah fitur, tipe feature map, kedalaman ansatz, dan pilihan optimizer untuk menilai sensitivitas kinerja QNN terhadap desain arsitektur. Mendokumentasikan konfigurasi yang paling stabil dan efisien sebagai rekomendasi desain QNN untuk GFD.

V.3 Analisis Risiko dan Mitigasi

Risiko kualitas dan ketersediaan data

Potensi ketidaklengkapan data (gap temporal, missing lokasi, noise) dari PLN atau NASA yang dapat menurunkan kualitas model. Mitigasi: menerapkan prosedur cleaning dan imputasi yang ketat, menyempitkan ruang lingkup ke periode/wilayah dengan kualitas data terbaik, serta menyiapkan alternatif fokus (mis. satu domain) jika data domain lain terlalu terbatas.

Risiko ketidakseimbangan dan non-stationarity GFD

Nilai GFD tinggi mungkin jarang, sehingga model cenderung bias ke nilai rendah/normal dan gagal menangkap ekor distribusi. Mitigasi: eksplorasi transformasi target (mis. log-GFD), penimbangan error (weighted loss), atau teknik resampling sederhana; fokus analisis khusus pada subset kejadian GFD tinggi.

Risiko keterbatasan komputasi dan konvergensi QNN

Simulator Qiskit dapat menjadi lambat untuk kombinasi qubit dan kedalaman sirkuit tertentu; pelatihan QNN berisiko mengalami barren plateaus atau tidak konvergen. Mitigasi: memulai dengan arsitektur sangat dangkal dan sedikit qubit, meningkatkan kompleksitas secara bertahap; mencoba beberapa jenis ansatz dan optimizer; menyiapkan baseline klasik yang solid sebagai fallback jika QNN tidak stabil.

Risiko akses dan stabilitas hardware kuantum

Akses ke IBM Quantum mungkin terbatas (antrian panjang, kuota tembak), dan noise perangkat dapat menurunkan kualitas hasil. Mitigasi: menjadikan simulator sebagai platform utama untuk seluruh analisis kuantitatif; menggunakan hardware nyata hanya sebagai demonstrasi kualitatif berskala kecil jika memungkinkan.

Risiko manajemen waktu dan lingkup skripsi

Batas waktu pengerjaan skripsi dapat terancam jika eksperimen terlalu banyak atau kompleksitas model tidak dikendalikan. Mitigasi: menetapkan milestone sesuai fase CRISP-DM, memprioritaskan skenario eksperimen utama (mis. satu baseline + satu konfigurasi QNN inti), dan membatasi eksplorasi tambahan hanya jika waktu memungkinkan.

Risiko kesulitan implementasi teknis Qiskit/QML

Kurva belajar Qiskit dan QML relatif curam, sehingga ada risiko bottleneck pada fase coding dan debugging. Mitigasi: memanfaatkan dokumentasi resmi Qiskit, contoh kode EstimatorQNN, dan memecah implementasi menjadi modul kecil (encoding, ansatz, training) yang diuji satu per satu sebelum digabungkan.

DAFTAR PUSTAKA

- Achmad Imam Agung dan Mahendra Widyartono, Arif Karta dan. 2020. “Analisis Kebutuhan Sistem Proteksi Sambaran Petir Pada Gedung Bertingkat”. *Jurnal Teknik Elektro* 9 (3).
- Denov, Bryan, Syarif Hidayat, Reynaldo Zoro, dan Suwarno. 2022. “Tropical Lightning Peak Current Measurement at West Java, Indonesia”. Dalam *2022 36th International Conference On Lightning Protection (ICLP)*. IEEE. <https://doi.org/10.1109/ICLP56858.2022.9942478>. <https://www.researchgate.net/publication/365444699>.
- Nicora, Martino, Mauro Tucci, Sami Barmada, Massimo Brignone, dan Renato Procopio. June 2024. “Lightning Location and Peak Current Estimation From Lightning-Induced Voltages on Transmission Lines With a Machine Learning Approach”. *IEEE Transactions on Electromagnetic Compatibility* 3, no. 66 () .
- Rith, Vicheka, Dara Vann, dan Luis Santos. June 2025. “Quantum Computing to Forecast Extreme Weather”. *Journal of Tecnologia Quantica* 2, no. 3 (): 125–134.
- Silva, Maria Helóisa F. da, Gleydson F. de Jesus, Christiano M. S. Nascimento, Valéria L. da Silva, dan Clebson S. Cruz. 2025. “Exploring Quantum Machine Learning for Weather Forecasting”.
- Society, American Meteorology. 2022. *Lightning*. <https://glossary.ametsoc.org/wiki/Lightning>.
- Wang, X., K. Hu, Y. Wu, dan W. Zhou. November 2023. “A Survey of Deep Learning-Based Lightning Prediction”. *Atmosphere* 14, no. 1698 () .