

**Model Prediksi *Ground Flash Density* (GFD) Petir
Wilayah Tropis serta Petir Wilayah Subtropis
Berbasis Komputasi Kuantum dengan Framework
Qiskit**

Proposal Tugas Akhir

Oleh

**Muhammad Rafly
18222067**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
12 Desember 2025**

LEMBAR PENGESAHAN

Model Prediksi *Ground Flash Density* (GFD) Petir Wilayah Tropis serta Petir Wilayah Subtropis Berbasis Komputasi Kuantum dengan Framework Qiskit

Proposal Tugas Akhir

Oleh

Muhammad Rafly
18222067

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 12 Desember 2025

Pembimbing 1

Pembimbing 2

Dr. Lenny Putri Yulianti, S.T., M.T.
NIP. 119110073

Dr. Bryan Denov, S.T., M.T.
NIP. 119110078

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	4
I.3 Tujuan	4
I.4 Batasan Masalah	5
I.5 Metodologi	5
I.5.1 Studi Literatur Sistematis	5
I.5.1.1 Protokol PRISMA	5
I.5.1.2 Concept Matrix (Webster & Watson)	6
I.5.2 Pengembangan Model (CRISP-DM)	6
II STUDI LITERATUR	8
II.1 Meteorologi Petir dan Ground Flash Density (GFD)	8
II.1.1 Konsep Dasar dan Metrik GFD	8
II.1.2 Faktor Meteorologis Pembentuk Petir	9
II.1.3 Disparitas Karakteristik: Tropis Versus Subtropis	9
II.2 Pendekatan Machine Learning Klasik	10
II.2.1 Algoritma <i>Deep Learning</i> (CNN/LSTM) untuk Nowcasting	10
II.2.2 Keterbatasan Komputasi Klasik	11
II.3 Komputasi Kuantum	12
II.4 Algoritma <i>Supervised Quantum Machine Learning</i> (QML)	12
II.4.1 <i>Quantum Generative Adversarial Networks</i> (QGAN)	12
II.4.2 <i>Quantum Neural Network</i> (QNN)	13
II.4.3 <i>Quantum Support Vector Regression</i> (QSVR)	15
II.4.4 <i>Quantum K Nearest Neighbors</i> (QkNN)	16
II.4.5 <i>Quantum Decision Tree</i> (QDT)	18
II.5 Implementasi pada Framework Qiskit	20
II.5.1 Komponen Ekosistem Qiskit	20
II.6 Tinjauan Penelitian Terdahulu dan Gap Analisis	21
II.6.1 Review Penelitian Terdahulu (QML in Meteorology)	21

II.6.2	Identifikasi Gap Penelitian	22
III	ANALISIS MASALAH	24
III.1	Analisis Kondisi Saat Ini	24
III.2	Analisis Kebutuhan	24
III.2.1	Identifikasi Masalah Pengguna	24
III.2.2	Kebutuhan Fungsional	25
III.2.3	Kebutuhan Nonfungsional	26
III.3	Analisis Pemilihan Solusi	26
III.3.1	Alternatif Solusi	26
III.3.2	Analisis Penentuan Solusi	26
IV	DESAIN KONSEP SOLUSI	29
V	RENCANA SELANJUTNYA	31
V.1	Rencana Implementasi	31
V.2	Desain Pengujian dan Evaluasi	32
V.3	Analisis Risiko dan Mitigasi	32

DAFTAR GAMBAR

II.1	Jaringan QNN (Beer 2022)	14
II.2	<i>Quantum perceptron</i> (Beer 2022)	14
II.3	Sirkuit QSVR (Tscharke dkk. 2024)	16
II.4	Sirkuit <i>Swap Test</i> (Basheer, Afham, dan Goyal 2024)	17
II.5	Sirkuit <i>Hadamard Test</i> (Basheer, Afham, dan Goyal 2024)	17
II.6	Algoritma QDT (Li dan Terashi 2025)	19
IV.1	Metodologi CRISP-DM	29
IV.2	Desain Konsep Solusi	29

DAFTAR TABEL

II.1	Deskripsi variabel dan satuan yang digunakan dalam dataset (Cheng, W.-Y. and Kim, D. and Ham, Y.-G. and Henderson, T. E. 2024)	9
III.1	Kebutuhan Fungsional Model Prediksi GFD Berbasis QNN	25
III.2	Kebutuhan Nonfungsional Model Prediksi GFD Berbasis QNN	26
III.3	Matriks Perbandingan dan Pembobotan Algoritma Kuantum untuk Prediksi GFD	28

DAFTAR KODE

BAB I

PENDAHULUAN

Bab pendahuluan menguraikan dasar pemikiran dan kerangka kerja awal dalam penyusunan tugas akhir. Pembahasan dimulai dengan pemaparan latar belakang yang menjelaskan urgensi serta motivasi pemilihan topik, diikuti dengan rumusan masalah yang mendetailkan inti persoalan yang akan diselesaikan. Selanjutnya, dipaparkan tujuan yang menjadi target pencapaian serta batasan masalah untuk memperjelas ruang lingkup pembahasan. Bab ini diakhiri dengan penjelasan metodologi yang menjabarkan tahapan sistematis yang dilakukan guna menjawab permasalahan tersebut.

I.1 Latar Belakang

Petir adalah pelepasan muatan listrik transien berarus tinggi di atmosfer dengan panjang lintasan yang diukur dalam kilometer (Society 2022). Terdapat beragam pendekatan untuk mengevaluasi intensitas sambaran petir. Salah satu evaluasi intensitas dapat dilihat dari pengukuran kerapatan petir atau *Ground Flash Density* (GFD). Secara umum, GFD didefinisikan sebagai laju kilat awan-ke-tanah (*ground flash rate*) yang diintegrasikan terhadap waktu, dinyatakan sebagai jumlah kilat per satuan luas (biasanya per kilometer persegi) (Mäkelä, Rossi, dan Schultz 2011).

Sambaran petir merupakan fenomena alam yang menjadi sumber risiko signifikan bagi manusia, struktur (misalnya, bangunan sipil dan turbin angin), infrastruktur (misalnya, transmisi dan distribusi tenaga listrik, serta sistem telekomunikasi), perkotaan, penerbangan, dan lingkungan alam (Nicora dkk. June 2024). Data satelit global menunjukkan bahwa terjadi sekitar 46 sambaran petir setiap detiknya di seluruh dunia, yang mengakibatkan lebih dari 10.000 korban jiwa dan kerugian ekonomi melebihi satu miliar USD setiap tahun (Wang dkk. November 2023). Sambaran petir menimbulkan dampak destruktif yang meliputi kerusakan struktur bangunan, risiko

kebakaran, kegagalan peralatan, hingga ancaman fatalitas bagi manusia (Achmad Imam Agung dan Mahendra Widyartono 2020). Berdasarkan statistik kegagalan tangki minyak, kebakaran tangki minyak yang disebabkan oleh petir terjadi hampir setiap tahun di Indonesia dalam kurun waktu 1995 hingga 2021. Kilang-kilang minyak di seluruh Indonesia terpaksa berhenti beroperasi akibat sambaran petir, yang menyebabkan banyaknya kasus kebakaran tangki serta kerusakan pada peralatan elektronik dan berbasis mikroprosesor sejak tahun 1995 (Denov dkk. 2022).

Indonesia, sebagai negara tropis yang dikelilingi oleh lautan dan memiliki arus udara naik (*updraft*) tinggi, menghadapi tantangan-tantangan unik. Indonesia memiliki hutan tropis yang luas sehingga tingkat kelembapannya tinggi. Selain itu, keberadaan banyak industri dan uap garam laut menyebabkan tingginya kandungan aerosol. Kondisi ini membuat wilayah Indonesia sangat kondusif bagi pembentukan awan Kumulonimbus yang menghasilkan petir. Di Indonesia, awan Kumulonimbus (CB) lebih lebar dibandingkan awan CB di wilayah subtropis. Petir di Indonesia memiliki gelombang ekor yang panjang (*long tail wave*), sehingga parameter muatan arusnya lebih besar dibandingkan dengan petir subtropis. Kerapatan sambaran petir di lokasi-lokasi tersebut juga relatif lebih tinggi (Denov dkk. 2022).

Model cuaca yang lebih akurat sangat dibutuhkan untuk memberikan peringatan dini yang lebih baik, mengurangi dampak bencana cuaca ekstrem, dan merencanakan mitigasi yang lebih efektif (Rith, Vann, dan Santos June 2025). Prediksi cuaca yang lebih akurat dapat meningkatkan kesiapsiagaan masyarakat dan mengurangi kerugian akibat bencana alam (Rith, Vann, dan Santos June 2025). Secara khusus, insinyur listrik membutuhkan data parameter petir dalam prosedur yang bertujuan untuk mengukur risiko petir bagi suatu struktur atau infrastruktur serta merancang sistem proteksi petir yang sesuai (Nicora dkk. June 2024). Statistik tersebut diharapkan dapat membantu insinyur dalam merancang sistem proteksi petir yang tepat berdasarkan data petir lokal (Denov dkk. 2022). Pada akhirnya, kemampuan prediktif ini sangat krusial bagi keselamatan jiwa, perlindungan harta benda, dan pemeliharaan keselamatan infrastruktur vital (Wang dkk. November 2023).

Saat ini, terdapat berbagai model prediksi petir yang memanfaatkan pendekatan tradisional, algoritma *machine learning* (ML), serta teknik *deep learning* (DL). Prediksi model numerik, yang mendasari sebagian besar metode prakiraan petir tradisional, memanfaatkan prinsip-prinsip dari dinamika atmosfer, termodinamika, dan bidang terkait untuk merumuskan model yang mensimulasikan proses atmosfer. Namun, akurasi model-model ini memerlukan peningkatan dikarenakan kompleksnya

proses fisik multi-skala yang terlibat dalam kejadian petir (Wang dkk. November 2023). Algoritma ML tradisional mencakup *decision trees* (DT), *support vector machines* (SVM), *random forests* (RF), *naive Bayes*, dan *simple ANNs*. Metode-metode ini sangat bergantung pada ekstraksi fitur manual, dengan konstruksi fitur secara manual menjadi komponen penting saat menerapkan algoritma *machine learning* tradisional ini dalam prediksi petir (Wang dkk. November 2023). Terbukti, metode DL, khususnya *Convolutional Neural Network* (CNN) dan *Recurrent Neural Network* (RNN), telah menunjukkan kinerja yang luar biasa saat menangani data spasial dan temporal multi-dimensi yang kompleks. Akurasi model-model tersebut masih menjadi area yang perlu ditingkatkan. Metodologi yang sederhana ini dapat mengabaikan keterkaitan yang rumit di antara parameter pengamatan atau fisika dasar yang memicu terjadinya petir (Wang dkk. November 2023). Di sisi lain, kemajuan teknologi komputasi telah membuka peluang bagi penerapan algoritma kuantum, seperti yang ditunjukkan dalam penelitian mengenai prediksi kerapatan petir menggunakan *Quantum Support Vector Regression* (QSVR) (Amri 2024). Pendekatan ini menawarkan paradigma baru untuk mengatasi kompleksitas data nonlinier yang mungkin sulit dijangkau oleh metode komputasi klasik.

Perkembangan terkini di bidang-bidang yang berdekatan (*adjacent fields*) telah menunjukkan keberhasilan penerapan komputasi kuantum dalam memecahkan permasalahan yang kompleks. Keunggulan dari model kuantum berasal dari sifat-sifat kuantum seperti *superposition* dan *entanglement*, yang memungkinkan kapasitas pemrosesan yang lebih besar dan identifikasi pola-pola kompleks yang mungkin tidak akan terdeteksi oleh model komputasi klasik (Silva dkk. 2025). Keberhasilan teknologi komputasi kuantum dalam bidang-bidang seperti optimasi dan pemodelan material menunjukkan bahwa teknologi ini memiliki potensi besar untuk menyelesaikan masalah yang berkaitan dengan kompleksitas dan ketidakpastian dalam sistem cuaca (Rith, Vann, dan Santos June 2025). Dalam penelitian meteorologi, komputasi kuantum telah mulai digunakan untuk mengembangkan algoritma dan model prediksi cuaca yang lebih efektif. Penelitian juga menunjukkan bahwa komputasi kuantum dapat membantu mempercepat simulasi iklim dan cuaca yang lebih kompleks, dengan meningkatkan kecepatan analisis data atmosfer yang besar dan meningkatkan pemrosesan data yang lebih efisien (Rith, Vann, dan Santos June 2025). Komputasi kuantum dengan studi-studi yang ada saat ini berfokus pada prediksi kecepatan angin, irradiansi matahari, pembangkitan daya angin dan fotovoltaik, badai geomagnetik, evapotranspirasi, dan presipitasi (Silva dkk. 2025).

Petir sebagai fenomena alam kuat menyebabkan kerusakan masif dan risiko kese-

lamatan. Hal ini menjadi isu kritis di Indonesia yang memiliki densitas petir tinggi dan tantangan geografis yang unik. Untuk memitigasi risiko ini, memprediksi parameter petir secara akurat sangatlah penting. Namun, penelitian saat ini masih bergantung pada *artificial intelligence* (AI) standar. Meskipun komputasi kuantum sudah menangani parameter cuaca, terdapat keterbatasan penelitian (*gap*) di mana kuantum belum diterapkan secara spesifik untuk prediksi petir.

I.2 Rumusan Masalah

Berdasarkan uraian di atas mengenai tantangan prediksi cuaca ekstrem dan evolusi teknologi komputasi, maka rumusan masalah yang diajukan dalam penelitian ini adalah:

1. Bagaimana merancang arsitektur komputasi kuantum pada framework Qiskit yang optimal untuk mengolah parameter input petir guna memprediksi nilai GFD?
2. Bagaimana karakteristik dan akurasi model kuantum tersebut dalam membedakan pola GFD pada wilayah Tropis dibandingkan dengan wilayah Subtropis, serta apakah model mampu melakukan generalisasi pada kedua domain data tersebut?
3. Bagaimana memformulasikan pemetaan matematis (*mapping*) dari parameter yang telah terlatih menjadi suatu fungsi prediksi yang dapat menerima input variabel atmosfer untuk menghasilkan nilai estimasi GFD?

I.3 Tujuan

Berdasarkan perumusan masalah dan latar belakang, maka tujuan yang diajukan dalam penelitian ini adalah:

1. Membangun dan mengimplementasikan model prediksi GFD berbasis algoritma kuantum menggunakan Qiskit dengan teknik data encoding yang tepat.
2. Mengevaluasi performa model dalam memprediksi GFD pada dataset wilayah Tropis dan Subtropis, serta menganalisis keunggulan atau kelemahan komputasi kuantum dibanding metode klasik pada dataset ini.
3. Menghasilkan suatu model komputasi (fungsi prediktor) yang tervalidasi, di mana parameter cuaca/petir dapat diinputkan ke dalam sirkuit kuantum yang telah dioptimasi untuk mengeluarkan nilai GFD.

I.4 Batasan Masalah

Batasan masalah dari tugas ini adalah:

1. Pembangunan solusi dengan memanfaatkan Qiskit sebagai *stack* untuk komputasi kuantum dan riset algoritma yang disimulasikan pada komputer pribadi.
2. Data yang digunakan diperoleh dari data historis *lightning detection system* (LDS) PLN Pusltibang dan NASA MERLIN.

I.5 Metodologi

Metodologi penelitian ini dirancang secara sistematis untuk memastikan tujuan penelitian tercapai dan menjawab rumusan masalah yang telah ditetapkan. Alur penelitian dibagi menjadi dua segmen utama, yaitu tinjauan literatur sistematis untuk membangun landasan teori dan kerangka kerja pengembangan model menggunakan standar industri.

I.5.1 Studi Literatur Sistematis

Tahap awal penelitian difokuskan pada pemahaman mendalam mengenai *state-of-the-art* dari topik. Proses ini dilakukan dengan ketat untuk menghindari bias dan memastikan relevansi referensi yang digunakan.

I.5.1.1 Protokol PRISMA

Untuk proses pencarian dan seleksi literatur, penelitian ini menerapkan protokol PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*). Protokol ini terdiri dari empat tahapan utama:

1. Melakukan identifikasi (*Identification*) dengan pencarian kata kunci pada basis data akademik.
2. Melakukan penyaringan (*Screening*) dengan memeriksa judul dan abstrak dari artikel yang ditemukan untuk meneliminasi duplikasi dan artikel yang tidak relevan dengan konteks.
3. Menentukan kelayakan (*Eligibility*) dengan membaca teks lengkap (*full-text*) dari artikel yang lolos tahap penyaringan. Artikel dinilai berdasarkan kriteria inklusi (misalkan dipublikasikan 5 tahun terakhir dan metode terkait) dan kriteria eksklusi.
4. Memastikan inklusi (*Included*) dengan menetapkan daftar akhir artikel yang akan dianalisis secara mendalam sebagai referensi utama penelitian.

I.5.1.2 Concept Matrix (Webster & Watson)

Setelah literatur terpilih, analisis dilakukan menggunakan pendekatan *Concept Matrix* yang diusulkan oleh Webster dan Watson (2002). Pendekatan ini mengubah pola tinjauan dari *author-centric* menjadi *concept-centric*. Analisis dimulai dengan mengelompokkan literatur berdasarkan konsep, variabel, atau metode yang digunakan, bukan sekadar meringkas per penulis. Kemudian matriks ini digunakan untuk memvisualisasikan area yang sudah banyak diteliti dan area yang belum terjamah, sehingga memvalidasi kebaruan (*novelty*) dari penelitian ini.

I.5.2 Pengembangan Model (CRISP-DM)

Metodologi pengembangan model dalam penelitian ini mengacu pada standar *Cross-Industry Standard Process for Data Mining* (CRISP-DM). Kerangka kerja ini terdiri dari enam tahapan siklus sebagai berikut:

1. *Business Understanding* (Pemahaman Bisnis)

Tahap pertama adalah memahami apa yang ingin dicapai oleh perusahaan. Fokusnya adalah menentukan tujuan bisnis, mendefinisikan kriteria kesuksesan, dan merancang rencana awal proyek data mining.

2. *Data Understanding* (Pemahaman Data)

Tahap mengumpulkan data awal, mempelajarinya untuk mendapatkan wawasan dasar, serta mengecek kualitas data (apakah ada data yang kotor/hilang) untuk memastikan data tersebut relevan dengan tujuan bisnis. *Data Preparation* (Persiapan Data)

Seringkali menjadi tahap yang paling memakan waktu. Ini adalah proses membersihkan data (*cleaning*), memilih fitur yang relevan, menggabungkan data, dan memformat ulang data mentah agar siap diproses oleh algoritma pemodelan.

3. *Modeling* (Pemodelan)

Tahap di mana teknik data mining atau algoritma ML diterapkan pada data yang sudah siap. Parameter model diatur dan dioptimalkan (*tuning*) untuk mendapatkan hasil terbaik.

4. *Evaluation* (Evaluasi)

Mengevaluasi model yang telah dibuat, bukan hanya dari sisi akurasi matematis, tetapi apakah model tersebut benar-benar menjawab masalah bisnis yang didefinisikan di tahap pertama. Jika belum sesuai, proses bisa kembali ke tahap awal.

5. *Deployment* (Penyebaran/Implementasi)

Tahap akhir di mana model diterapkan ke dalam operasional bisnis sehari-hari agar pengguna akhir bisa memanfaatkannya, atau sekadar pembuatan laporan akhir dari pengetahuan yang didapat.

BAB II

STUDI LITERATUR

II.1 Meteorologi Petir dan Ground Flash Density (GFD)

II.1.1 Konsep Dasar dan Metrik GFD

Pengukuran dan pemodelan *Ground Flash Density* (GFD) sangat bergantung pada ketersediaan data petir yang andal dari pengamatan satelit. Sensor satelit seperti *Lightning Imaging Sensor* (LIS) dan *Optical Transient Detector* (OTD) mencatat petir sebagai "events" pada array pencitraan *Charge-Coupled Device* (CCD), yang merepresentasikan peristiwa optik mentah akibat kilatan cahaya petir. Untuk mengidentifikasi sambaran petir yang sesungguhnya, data events ini harus melalui tahap pemrosesan tambahan berupa *filtering* dan *clustering*, sehingga diperoleh struktur data bertingkat berupa *groups*, *flashes*, dan *areas* (Peterson, Mach, dan Buechler 2021).

Dalam pemrosesan standar LIS/OTD, *groups* didefinisikan sebagai kluster iluminasi puncak awan dari pulsa-pulsa cahaya individu, *flashes* didefinisikan sebagai rangkaian pulsa yang menggambarkan satu kilat yang utuh, sedangkan *areas* merepresentasikan kluster aktivitas petir yang menggambarkan *snapshot* badai. Dalam konteks GFD, penting untuk membedakan antara *events*, *groups*, dan *flashes* karena GFD didefinisikan sebagai jumlah sambaran petir ke darat (*ground flashes*) per satuan luas dan waktu (misalnya per km² per tahun), sehingga skema klasifikasi ini menjadi dasar untuk menghitung densitas sambaran yang menjadi target prediksi. LIS/OTD berfungsi sebagai salah satu sumber *ground truth* global utama yang relevan untuk memvalidasi model-model prediksi GFD, termasuk model berbasis komputasi kuantum yang dikembangkan pada tesis ini (Peterson, Mach, dan Buechler 2021).

II.1.2 Faktor Meteorologis Pembentuk Petir

Pembentukan petir sangat dipengaruhi oleh kondisi termodinamika dan dinamika atmosfer yang dapat direpresentasikan melalui variabel-variabel meteorologis skala besar. Pada sebuah studi parameterisasi petir berbasis ML, himpunan data pelatihan dirangkum dalam Tabel II.1 dengan variabel input yang mencakup presipitasi (P) dan berbagai variabel medan atmosfer, seperti *convective available potential energy* (CAPE), ketinggian geopotensial 500 hPa (Z_{500}), ketinggian geopotensial 1000 hPa (Z_{1000}), ketebalan antara level 300–700 hPa ($Z_{300-700}$), suhu pada 2-m (T_{2M}), kecepatan vertikal pada 500 hPa, serta suhu titik embun pada 2-m (2-m *dewpoint temperature*) (Cheng, W.-Y. and Kim, D. and Ham, Y.-G. and Henderson, T. E. 2024).

Tabel II.1 Deskripsi variabel dan satuan yang digunakan dalam dataset (Cheng, W.-Y. and Kim, D. and Ham, Y.-G. and Henderson, T. E. 2024)

Dataset	Akronim variabel	Deskripsi (satuan)
WWLLN	f	Kerapatan kilatan petir (kilatan per kilometer persegi per tahun)
TRMM	P	Presipitasi (mm h^{-1})
ERA5	CAPE	Energi potensial konvektif yang tersedia (J kg^{-1})
	T_{2M}	Suhu 2-m (K)
	Z_{500}	Geopotensial 500-hPa ($10^3 \text{ m}^2 \text{ s}^{-2}$)
	Z_{1000}	Geopotensial 1000-hPa ($10^3 \text{ m}^2 \text{ s}^{-2}$)
	$Z_{300-700}$	Ketebalan antara level 300 dan 700 hPa ($10^3 \text{ m}^2 \text{ s}^{-2}$)
	W_{500}	Kecepatan vertikal 500-hPa (Pa s^{-1})
	D_{2M}	Suhu titik embun 2-m (K)

CAPE pada studi tersebut digunakan sebagai indikator utama ketidakstabilan atmosfer yang mendukung konveksi kuat, sedangkan presipitasi (P) dan suhu titik embun 2m secara langsung terkait dengan ketersediaan uap air dan kelembaban yang menjadi prasyarat pembentukan awan konvektif dan petir. Variabel-variabel atmosfer skala besar ini terbukti penting dalam parameterisasi petir dan, dalam konteks tesis ini, dapat difungsikan sebagai fitur input klasik untuk model *Quantum Neural Network* (QNN) yang dikembangkan untuk memprediksi GFD (Cheng, W.-Y. and Kim, D. and Ham, Y.-G. and Henderson, T. E. 2024).

II.1.3 Disparitas Karakteristik: Tropis Versus Subtropis

Indonesia digambarkan sebagai negara tropis yang terletak di sekitar ekuator dan dikelilingi oleh lautan, sehingga mengalami cuaca panas sepanjang tahun. Karakter

maritim dengan banyak pulau ini menghasilkan aerosol dalam jumlah besar, terutama dari garam laut, sedangkan iklim yang lembab dengan hutan, sungai, dan danau yang melimpah menjadi faktor utama pembentukan awan kumulonimbus (CB) sebagai awan penghasil petir. Kondisi-kondisi ini menjadikan wilayah tropis maritim seperti Indonesia sangat kondusif terhadap aktivitas petir yang intensif (Denov dkk. September 2023).

Studi lain menegaskan bahwa terdapat disparitas yang signifikan antara perilaku petir di iklim tropis dan subtropis (Denov dan Zoro 2025). Investigasi ekstensif selama delapan tahun di Stasiun Penelitian Petir Gunung Tangkuban Perahu menemukan berbagai karakteristik unik petir tropis, menandakan bahwa karakteristik kilat di wilayah tropis tidak dapat secara langsung disamakan dengan petir di wilayah subtropis (Denov dkk. September 2023). Perbedaan ini menjustifikasi perlunya model prediksi yang secara eksplisit mempertimbangkan perbedaan iklim tropis dan subtropis, terutama ketika standar proteksi petir internasional yang dominan berbasis pada karakteristik subtropis hendak diterapkan di wilayah tropis (Denov dan Zoro 2025).

II.2 Pendekatan Machine Learning Klasik

II.2.1 Algoritma *Deep Learning* (CNN/LSTM) untuk Nowcasting

Dalam ranah prediksi petir berbasis komputasi klasik, DL telah mencapai tingkat kompleksitas arsitektur yang tinggi. Salah satu contoh adalah model LightningNet yang menggunakan arsitektur *encoder-decoder* dengan 20 lapisan konvolusional tiga dimensi, lapisan *pooling* dan *upsampling*, lapisan normalisasi, serta *softmax classifier*. Arsitektur ini dirancang untuk memproses data multi-sumber dalam format spasial atau citra, seperti data satelit, radar, dan lokasi petir, sehingga mampu melakukan *nowcasting* petir cloud-to-ground (CG) dengan resolusi yang tinggi. Model-model seperti LightningNet menunjukkan bahwa prediksi petir modern menuntut pemrosesan informasi spasial yang sangat kompleks, yang menjadi tolok ukur kinerja bagi model QNN yang akan dikembangkan (Zhou dkk. 2020).

Di sisi lain, RNN dirancang khusus untuk memproses data urutan (*sequence data*) dengan memprosesnya secara iteratif dalam arah sekuensial. Dalam konteks prediksi petir, RNN sering direalisasikan sebagai *long short-term memory* (LSTM) yang dikembangkan untuk mengatasi masalah ketergantungan jangka panjang yang sulit ditangani oleh RNN standar. Prediksi GFD yang memanfaatkan deret waktu variabel-variabel meteorologis seperti CAPE dan kelembaban dari waktu ke waktu

sangat relevan dengan kemampuan LSTM dalam menangkap ketergantungan temporal jangka panjang. Kombinasi CNN dan LSTM menghasilkan arsitektur ConvLSTM yang lazim digunakan untuk prediksi *spatiotemporal* dalam meteorologi, dan fakta ini menandakan bahwa QNN yang dikembangkan dalam penelitian ini juga harus mampu menangani dependensi temporal secara efektif (Zhou dkk. 2020).

II.2.2 Keterbatasan Komputasi Klasik

Penggunaan *Earth Observation* (EO) dan data cuaca dalam jumlah besar untuk prediksi cuaca ekstrem menyebabkan kompleksitas waktu komputasi yang sangat tinggi pada pendekatan komputasi klasik (Munasinghe dkk. 2024). Studi deep learning untuk prediksi petir, seperti LightningNet, menunjukkan bahwa model tersebut memiliki parameter yang dapat dilatih dalam jumlah sangat besar, misalnya hingga 29.128.577 parameter, sehingga pelatihan dan inferensi menjadi sangat mahal secara komputasi (Zhou dkk. 2020). Volume data yang besar dikombinasikan dengan kebutuhan akurasi tinggi membatasi penerapan model klasik skala penuh, dan hal ini membuka peluang bagi *quantum machine learning* (QML) yang menjanjikan pemrosesan data besar secara paralel dengan kecepatan dan presisi yang lebih baik (Munasinghe dkk. 2024).

Selain itu, atmosfer digambarkan sebagai sistem dinamis dan kacau (*dynamic and chaotic system*), dengan variasi kecil pada kondisi awal dapat menyebabkan perubahan signifikan pada kondisi di masa depan. Sifat *chaotic* dan kompleksitas nonlinear ini menyulitkan model klasik untuk memberikan prediksi yang akurat, terutama pada rentang waktu lebih panjang atau untuk peristiwa ekstrem seperti GFD tinggi. Meskipun CNN dan LSTM mampu memodelkan sistem nonlinear yang kompleks, generalisasi terhadap data yang tidak seimbang atau jarang terjadi, seperti sambaran petir ekstrem, tetap menjadi tantangan nyata bagi DL klasik (Silva dkk. 2025).

Studi lain menunjukkan bahwa ketika badai petir disimulasikan pada skala yang lebih kecil dengan resolusi spasial dan temporal yang lebih halus, prediktabilitas kejadiannya justru berkurang. Akurasi prediksi cenderung menurun seiring dengan peningkatan resolusi karena ketidakpastian prakiraan numerik (NWP) yang meningkat, sehingga terdapat batas fisik pada prediktabilitas sistem atmosfer (Vahid Yousefnia dkk. 2024). Dalam konteks ini, QML diharapkan dapat mengimbangi peningkatan ketidakpastian melalui keunggulan komputasi dan representasi ruang fitur berdimensi tinggi (Munasinghe dkk. 2024).

II.3 Komputasi Kuantum

Komputasi kuantum adalah cara komputasi modern yang didasarkan pada ilmu mekanika kuantum dan fenomena luar biasa yang ditimbulkannya. Ini adalah kombinasi antara fisika, matematika, ilmu komputer, dan teori informasi, dan merupakan jenis komputasi baru yang berurusan dengan dunia fisik yang bersifat probabilistik dan tidak dapat diprediksi. Komputasi kuantum memanfaatkan tiga sifat mendasar mekanika kuantum superposisi, *entanglement* (keterikatan), dan *interference* (interferensi) untuk menyimpan, merepresentasikan, dan melakukan operasi pada data. Untuk menyimpan dan memanipulasi informasi, sistem ini menggunakan quantum bits atau *qubits*, yang merupakan unit fundamental informasi kuantum dan merepresentasikan partikel subatom seperti atom, elektron, atau foton. Berbeda dengan bit klasik yang hanya memiliki nilai 0 atau 1 secara individual, *qubit* dapat memiliki nilai 0, 1, atau keduanya secara bersamaan karena sifat superposisi. Dengan mengendalikan perilaku objek fisik kecil (partikel mikroskopis), komputasi kuantum dapat memberikan daya komputasi yang tinggi dan kecepatan eksponensial yang jauh melampaui komputer klasik (Marella dan Parisa 2020).

II.4 Algoritma *Supervised Quantum Machine Learning* (QML)

II.4.1 *Quantum Generative Adversarial Networks* (QGAN)

Arsitektur QGAN yang diusulkan mensintesis pemodelan generatif klasik dengan prinsip *quantum computing* dengan memetakan permainan *adversarial minimax* ke dalam *Hilbert space* \mathcal{H} . Dalam kerangka kerja ini, *generator* dan *discriminator* konvensional digantikan oleh *quantum operators*, \hat{U}_G dan \hat{U}_D , yang mengevolusi *quantum states* melalui *unitary transformations*, bukan lapisan *neural network* klasik. Arsitektur ini bekerja dengan mengevolusi *initial quantum state* $\hat{\rho}_0$ menuju distribusi target yang mengaproksimasi data yang sebenarnya. Desain ini memperkenalkan *terms* khusus berbasis kuantum, \hat{V}_G dan \hat{V}_D , ke dalam *Hamiltonians* milik *generator* dan *discriminator*. Augmentasi ini menciptakan sinergi *hybrid quantum-classical* yang bertujuan untuk mengeksplorasi *superposition* dan *entanglement* guna mempercepat proses evolusi *state*, yang secara fundamental mendefinisikan ulang dinamika *training* dibandingkan dengan *baseline* klasik (Nokhwal dkk. 2023).

Formulasi matematis ini bergantung pada representasi *density matrix* untuk mendefinisikan *cost function*. Sebagaimana disempurnakan dalam Persamaan II.1, *objective function* yang ditingkatkan secara kuantum dinyatakan sebagai berikut (Nokhwal dkk. 2023).

$$\min_{\hat{U}_G} \max_{\hat{U}_D} \text{Tr}(\hat{\rho}_r \hat{U}_D) + \text{Tr}(\hat{\rho}_g \hat{U}_G \hat{U}_D) \quad (\text{II.1})$$

Tr menunjukkan operasi *trace*, sedangkan $\hat{\rho}_r$ dan $\hat{\rho}_g$ masing-masing merepresentasikan *density matrices* dari *quantum states* asli dan yang dibangkitkan. Komponen penting dari kerangka kerja ini adalah strategi *quantum data encoding* yang fitur data klasik p_i dipetakan ke dalam *quantum basis states* ψ_i . Evolusi dari *quantum operators* diatur oleh simulasi *Hamiltonian*; secara khusus, evolusi *unitary* dari *generator* yang diaugmentasi didefinisikan dalam Persamaan II.2 sebagai berikut (Nokhwal dkk. 2023).

$$\hat{U}_G = e^{-i(\hat{H}_G + \lambda \hat{V}_G)t} \quad (\text{II.2})$$


Di sini, λ adalah parameter kontrol yang memodulasi pengaruh *quantum-enhanced term* \hat{V}_G untuk mengoptimalkan lintasan konvergensi *training*.

Pengaturan eksperimental yang dijelaskan dalam makalah ini bersifat teoritis, menguraikan peta jalan untuk validasi masa depan pada prosesor kuantum dengan n *qubits*. Implementasi teknik QGAN yang diusulkan bersifat prospektif karena keterbatasan perangkat keras saat ini. Studi ini mengusulkan penilaian kinerja menggunakan metrik generatif standar seperti *Inception Score* dan *Fréchet Inception Distance* (FID) pada pelaksanaan di masa mendatang. Hasil yang diantisipasi, menunjukkan bahwa integrasi mekanisme *quantum speedup* berbasis *Hamiltonian* akan secara signifikan mengurangi jumlah iterasi yang diperlukan untuk konvergensi dibandingkan dengan metode klasik, meskipun data empiris yang mendukung peningkatan efisiensi spesifik ini belum dihasilkan (Nokhwal dkk. 2023).

II.4.2 Quantum Neural Network (QNN)


Quantum Neural Network (QNN) adalah sebuah arsitektur *feed-forward* yang dirancang untuk meniru logika struktural *neural networks* klasik sambil beroperasi sepenuhnya dalam kerangka kerja mekanika kuantum. Sebagaimana diilustrasikan dalam Gambar II.1, jaringan ini terdiri dari $L + 2$ *layer qubit*, yang disusun dari *input layer* hingga *output layer*, dengan *hidden layers* di antaranya (Beer 2022).

Blok pembangun fundamental dari arsitektur ini adalah *quantum perceptron*, yang digambarkan dalam Gambar II.2, yang menghubungkan *neurons* (*qubit*) antara *layer* $l - 1$ dan *layer* l . *Perceptron* ini diimplementasikan sebagai operasi *unitary* yang



Gambar II.1 Jaringan QNN (Beer 2022)

bekerja pada *qubit* di *layer* saat ini serta *qubit* baru di *layer* berikutnya yang diinisialisasi dalam *state* 0, diikuti dengan operasi *tracing out* pada *qubit* dari *layer* sebelumnya. Operasi *partial trace* ini menjadikan transisi antar-*layer* bersifat disipatif, yang mencegah pembalikan aliran informasi dan secara formal menstrukturkan jaringan sebagai rantai interaksi lokal alih-alih satu *unitary* global tunggal. Desain sirkuit yang dihasilkan memungkinkan pengurangan kebutuhan memori selama *training*, karena optimasi *perceptron* tertentu hanya memerlukan akses ke *quantum states* dari *layer* tetangga terdekatnya (Beer 2022).



Gambar II.2 *Quantum perceptron* (Beer 2022)

Formulasi matematis memperlakukan QNN sebagai komposisi dari *layer-to-layer completely positive* (CP) *maps*. Propagasi sebuah *input state* ρ^{in} melalui jaringan menuju *output* ρ^{out} didefinisikan dalam Persamaan II.3 sebagai berikut (Beer 2022).

$$\rho^{\text{out}} = \mathcal{E}(\rho^{\text{in}}) = \mathcal{E}^{L+1}(\dots \mathcal{E}^1(\rho^{\text{in}}) \dots) \quad (\text{II.3})$$

Setiap \mathcal{E}^l merepresentasikan peta transisi. Proses *training* bergantung pada *supervised learning* yang menggunakan pasangan *input* dan *output quantum states* yang


diinginkan. *Cost function* didefinisikan sebagai *fidelity* antara *output* jaringan dan target *output*, yang dirata-ratakan pada *training set*. Untuk mengoptimalkan jaringan, penulis menurunkan analog kuantum terhadap algoritma *back-propagation*. Parameter *unitary* diperbarui melalui matriks $K_j^l(t)$ yang diturunkan. Matriks pembaruan ini memerlukan penentuan *adjoint channel* \mathcal{F}_t^l untuk melakukan *back-propagate error* dari *output layer*, yang secara efektif membentuk mekanisme *gradient descent* yang beroperasi langsung pada *unitary manifold* dari *perceptrons* (Beer 2022).

Evaluasi eksperimental berfokus pada tugas mengkarakterisasi operasi *unitary* yang tidak diketahui menggunakan simulasi klasik dan eksekusi pada perangkat *NISQ*. Dalam simulasi klasik, QNN menunjukkan konvergensi yang cepat, dengan *training* dan *validation losses* mendekati *fidelity* 1 dalam 1000 *epochs* untuk sejumlah kecil pasangan *training*. Jaringan mempertahankan *validation fidelities* yang tinggi bahkan ketika *noise* yang signifikan dimasukkan ke dalam data *training*. Selanjutnya, perluasan model menggunakan data terstruktur dan *generative adversarial training* menunjukkan bahwa arsitektur ini dapat diadaptasi untuk meningkatkan generalisasi dan menghasilkan data kuantum (Beer 2022).

II.4.3 Quantum Support Vector Regression (QSVR)

Model *Quantum Support Vector Regression* (QSVR) *semi-supervised* yang dirancang khusus untuk *anomaly detection* (AD) pada perangkat *Noisy Intermediate-Scale Quantum* (NISQ). Inti dari arsitektur ini adalah metode *quantum kernel* yang menghitung kesamaan antar titik data dalam *feature space* berdimensi tinggi. Seperti diilustrasikan dalam Gambar II.3, estimasi *kernel* diimplementasikan melalui sirkuit *inversion test* (atau *overlap test*). Sirkuit ini menerapkan *unitary feature map* $U(x_i)$ yang meng-*encode* titik data pertama, diikuti segera oleh *adjoint unitary* $U^\dagger(x_j)$ yang meng-*encode* titik data kedua. *Ansatz* spesifik untuk U terdiri dari satu *layer gate* R_Z dan satu *layer gate* R_X untuk meng-*encode* fitur individu, diikuti oleh satu *layer gate* *IsingZZ* untuk menghasilkan *entanglement* antar *qubit*. Nilai *kernel* K_{ij} diekstraksi dengan mengukur probabilitas *quantum register* kembali ke *state nol-semua* $0 \dots 0$ setelah rangkaian operasi tersebut (Tscharke dkk. 2024).

Kerangka teoretis bergantung pada pemetaan data klasik x ke dalam *Hilbert space* \mathcal{F} melalui *feature map* Persamaan II.4. Studi ini menggunakan *angle encoding*, sebuah bentuk *time-evolution encoding* yang dijelaskan oleh evolusi uniter dalam Persamaan II.5, dengan *Hamiltonian* H menggunakan matriks Pauli. *Quantum kernel* didefinisikan secara ketat sebagai *fidelity* antara dua *quantum states* yang di-*encode*, yang dinyatakan secara matematis dalam Persamaan II.6 (Tscharke dkk. 2024).



Gambar II.3 Sirkuit QSVM (Tscharke dkk. 2024)

$$\phi : \mathcal{X} \rightarrow \mathcal{F} \quad (\text{II.4})$$

$$U(x) = e^{-ixH} \quad (\text{II.5})$$

$$\kappa(x_i, x_j) = |\langle \phi(x_i) | \phi(x_j) \rangle|^2 \quad (\text{II.6})$$


Untuk menganalisis *robustness*, penulis memodelkan lingkungan perangkat keras menggunakan representasi *operator-sum* dari *quantum channels*. Mereka memformalkan interaksi *noise* spesifik secara matematis, seperti *Amplitude Damping* dan *Phase Damping*, untuk mensimulasikan degradasi matriks *kernel* di bawah kondisi NISQ yang realistis (Tscharke dkk. 2024).

Validasi eksperimental melakukan *benchmark* QSVM pada IBM Quantum System One 27-qubit berbasis superkonduktor terhadap model kuantum yang disimulasikan dan *baseline* klasik (CSVM, Autoencoder) di sebelas dataset. Model berbasis perangkat keras (qc-QSVM) menunjukkan performa kompetitif, yang secara mengejutkan mengungguli simulasi tanpa *noise* (*noiseless simulation*) pada dataset Credit Card (CC) dan KDD, menunjukkan adanya efek regularisasi yang menguntungkan dari *hardware noise*. Namun, simulasi *noise* ekstensif mengungkapkan bahwa meskipun model tersebut *robust* terhadap *depolarizing* dan *bit-flip errors*, model ini sangat sensitif terhadap *amplitude damping* dan *miscalibration noise* (Tscharke dkk. 2024).


II.4.4 Quantum K Nearest Neighbors (QkNN)

Arsitektur QkNN yang diusulkan bekerja dengan mereduksi pencarian *nearest neighbor* menjadi sebuah instansi dari algoritma *quantum k maxima finding*. Inti dari desain sirkuit ini adalah konstruksi *oracle* spesifik, $\mathcal{O}_{y,A}$, yang menandai indeks

dari *training states* yang memiliki *similarity* lebih tinggi terhadap *test state* dibandingkan dengan *threshold index* y yang dipilih secara acak. Proses ini bergantung pada *quantum subroutine* modular yang melibatkan tiga tahap: *analog encoding*, konversi analog-ke-digital, dan komparasi. Pertama, metrik *similarity* di-encode ke dalam amplitudo menggunakan sirkuit *Swap Test* pada Gambar II.4 untuk *fidelity* atau *Hadamard Test* pada Gambar II.5 untuk *dot products*. Amplitudo ini kemudian didigitalkan menggunakan skema *Quantum Analog-to-Digital Conversion* (QADC) yang dimodifikasi dan menggunakan *Quantum Phase Estimation* (QPE) untuk meregistrasi nilai *similarity* ke dalam *computational basis*. Terakhir, pencarian berbasis *Grover* mengiterasi struktur ini untuk mengidentifikasi dan mengganti indeks dalam himpunan A hingga k *nearest neighbors* terisolasi (Basheer, Afham, dan Goyal 2024).



Gambar II.4 Sirkuit *Swap Test* (Basheer, Afham, dan Goyal 2024)



Gambar II.5 Sirkuit *Hadamard Test* (Basheer, Afham, dan Goyal 2024)

Formulasi matematis berpusat pada pendefinisian ukuran *similarity*—baik berupa *fidelity* sebagaimana didefinisikan dalam II.9, atau *dot product* sebagaimana didefinisikan dalam II.8. Rumus dirancang sedemikian rupa sehingga *eigenstates*-nya meng-encode informasi *fidelity* dalam *eigenvalues*, dengan hubungan antara fase dan *fidelity*. Strategi *encoding* ini memungkinkan algoritma untuk melakukan perbandingan aritmatika pada *quantum states* tanpa memerlukan deskripsi klasik, yang secara fundamental bergantung pada konversi digital fase θ_j yang diekstraksi melalui QPE (Basheer, Afham, dan Goyal 2024).

$$F(\psi, \phi_j) = |\langle \psi | \phi_j \rangle|^2 \quad (\text{II.7})$$

$$X(v, u_j) \quad (\text{II.8})$$

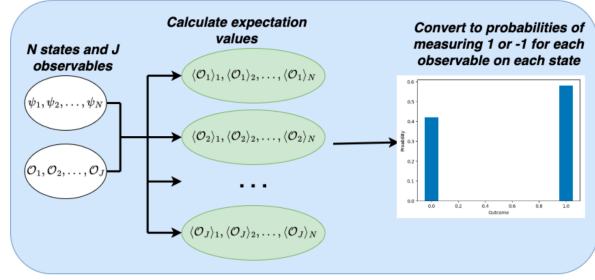
Algoritma ini divalidasi dengan menerapkannya pada klasifikasi *entanglement* dan diskriminasi *quantum state*, dengan mengajukan *query complexity* sebesar $O(\sqrt{kM})$ dengan M sebagai jumlah *training states*. Ini merepresentasikan *quadratic speedup* dibandingkan dengan pencarian klasik yang menyeluruh (*exhaustive search*). Simulasi numerik dilakukan untuk mengklasifikasikan n -qubit states ke dalam kelas *entanglement* yang berbeda (misalnya, *separable* melawan *entangled*). QkNN yang diusulkan ini sangat berbeda karena beroperasi langsung pada data kuantum melalui sirkuit *state preparation*, sehingga melewati proses *quantum state tomography*, yaitu sebuah proses mahal yang biasanya diperlukan oleh kNN klasik atau varian kuantum lain yang bergantung pada deskripsi *state* klasik secara eksplisit (Basheer, Afham, dan Goyal 2024).

II.4.5 *Quantum Decision Tree* (QDT)

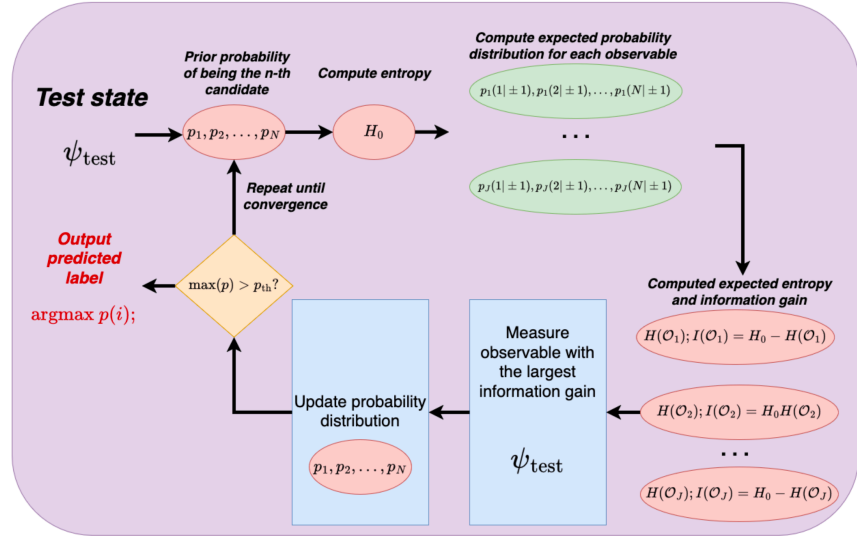
Metode *Quantum Decision Tree* merupakan kerangka kerja klasifikasi *ansatz-free* yang berbeda dari *Variational Quantum Algorithms* (VQAs) tradisional karena tidak memerlukan *loops* optimisasi sirkuit yang terparameterisasi. Sebaliknya, arsitektur ini menggunakan logika *decision-tree* klasik dengan setiap *nodes* merepresentasikan pengukuran kuantum fisik pada *test state* spesifik. Seperti diilustrasikan pada II.6, proses dimulai dengan mempersiapkan himpunan *candidate states* dan melakukan pra-komputasi *expectation values* untuk sekumpulan *observables* yang tersedia. Mekanisme inti beroperasi sebagai *greedy search* dengan setiap langkah, algoritma memilih *observable* spesifik \mathcal{O}_j yang memaksimalkan *expected information gain*, melakukan pengukuran *single-shot*, dan memperbarui distribusi probabilitas pada kelas kandidat secara klasik. Struktur *hybrid* ini mengisolasi sumber daya kuantum secara eksklusif untuk akuisisi data (*state preparation* dan pengukuran), sementara logika inferensi tetap sepenuhnya klasik, sehingga menghindari kompleksitas pelatihan yang umumnya terkait dengan *Quantum Neural Networks* (QNNs) (Li dan Terashi 2025).

Landasan matematis algoritma ini bergantung pada minimalisasi *Shannon entropy* dari distribusi *candidate state* melalui *Bayesian inference*. Setelah mengukur sebuah *observable* \mathcal{O}_j dengan hasil ± 1 , probabilitas $p(i)$ bahwa *test state* tersebut berkorepondensi dengan kandidat ke- i diperbarui menurut II.9, yang memanfaatkan probabilitas kondisional yang diturunkan dari *expectation value* kandidat yang telah di-

Preparation



Algorithm



Gambar II.6 Algoritma QDT (Li dan Terashi 2025)

hitung sebelumnya $\langle \mathcal{O}_j \rangle_i$. Metrik optimisasi yang digunakan adalah *expected information gain*, didefinisikan sebagai selisih antara *prior entropy* H_0 dan *expected posterior entropy* $H(\mathcal{O}_j)$. Derivasi ini membuktikan secara matematis bahwa untuk *Haar-random states* yang tidak terstruktur, *information gain* mengalami supresi eksponensial seiring dengan ukuran sistem N (berskala $1/2^n$), sebuah fenomena yang secara struktural mirip dengan masalah *barren plateau* dalam *gradient-based quantum learning* (Li dan Terashi 2025).

$$p_j(i|\pm 1) = \frac{p(i)(1 \pm \langle \mathcal{O}_j \rangle_i)}{\sum_{k=0}^N p(k)(1 \pm \langle \mathcal{O}_j \rangle_k)} \quad (\text{II.9})$$

Validasi eksperimental dilakukan menggunakan simulasi 10-*qubit* dan prosesor kuantum IBM Kawasaki untuk menilai efisiensi *classifier*. Strategi yang dioptimalkan informasinya (*information-optimized*) mencapai konvergensi pada tingkat kepercayaan 99% ($p\text{-value} < 0.01$) dalam waktu sekitar 150 *shots*, secara signifikan mengungguli protokol pengukuran acak atau statis. Penggunaan *observables* yang termotivasi secara fisik (yang terdapat dalam Hamiltonian) menghasilkan *informa-*

tion gain yang jauh lebih tinggi dibandingkan *Pauli operators* acak, sehingga secara efektif menghindari masalah supresi eksponensial. Meskipun metode ini terbukti *robust* pada perangkat keras IBM Kawasaki yang *noisy* dibandingkan dengan *baseline* variasional, hasilnya menyoroti bahwa *noise* perangkat keras tetap menurunkan resolusi *expectation values*, sehingga memerlukan teknik mitigasi kesalahan seperti *randomized Pauli twirling* dan *zero noise extrapolation* (Li dan Terashi 2025).

II.5 Implementasi pada Framework Qiskit

II.5.1 Komponen Ekosistem Qiskit

Qiskit merupakan *software development kit open-source* untuk *quantum information science* yang dikembangkan dengan arsitektur berbasis sirkuit. Kerangka kerja ini bertumpu pada tiga komponen utama, yaitu *circuits*, *pass managers*, dan *primitives* (Sahin dkk. 2025). *Pass managers* digunakan untuk mengoptimasi sirkuit kuantum, sedangkan *primitives* menyediakan antarmuka standar untuk mengevaluasi sirkuit pada perangkat kuantum, sehingga esensial dalam melatih model QNN (Sutor 2019).

Dalam komputasi kuantum, terdapat dua *primitives* utama untuk menangkap keluaran sirkuit kuantum, yakni *sampling output bitstrings* dan estimasi *observable expectation values*. *Primitives* diimplementasikan sebagai *sampler* dan *estimator*, dengan *EstimatorQNN* memanfaatkan *BaseEstimator* primitive dari Qiskit untuk mengintegrasikan sirkuit kuantum berparameter dengan *observables* mekanika kuantum (Javadi-Abhari dan al. 2024). Dalam konteks prediksi GFD, estimator digunakan untuk mengukur nilai ekspektasi operator yang kemudian menjadi keluaran prediksi seperti probabilitas GFD tinggi (Munasinghe dkk. 2024).

Qiskit dirancang sebagai kerangka kerja ringan yang dapat diintegrasikan ke dalam lingkungan *runtime* yang mengkolokasikan prosesor kuantum dengan prosesor klasik umum, sehingga ribuan sirkuit dapat dihasilkan dan dievaluasi secara dinamis untuk memperoleh solusi akhir. Contoh lingkungan runtime ini adalah Qiskit *Runtime* yang diimplementasikan pada komputer kuantum IBM, yang memungkinkan algoritma *hybrid* seperti QNN/VQR dioptimalkan secara efisien melalui interaksi intensif antara *optimizer* klasik dan prosesor kuantum yang mengeksekusi sirkuit dan mengukur *primitives* (Javadi-Abhari dan al. 2024).

II.6 Tinjauan Penelitian Terdahulu dan Gap Analisis

II.6.1 Review Penelitian Terdahulu (QML in Meteorology)

Penelitian QML dalam meteorologi dan *environmental forecasting* telah menunjukkan potensi signifikan, terutama dalam menangani data deret waktu dan kompleksitas nonlinear yang tinggi (Pandey dkk. 2025). Sebagian besar studi awal QML berfokus pada prediksi energi (seperti kecepatan angin dan iradiasi matahari) serta klasifikasi iklim, karena data tersebut memiliki karakteristik *time-series* yang mirip dengan data GFD (Silva dkk. 2025).

Sebuah studi membandingkan berbagai pendekatan untuk memprediksi suhu permukaan global termasuk metode *classical machine learning* seperti ARMA, ARIMA, dan SARIMA, jaringan saraf seperti LSTM, CNN-LSTM, dan ConvLSTM, serta teknik QML seperti QNN, VQR, dan QSVR. Hasilnya menunjukkan bahwa QSVR menjadi model unggulan untuk *time-series forecasting* karena kemampuannya memanfaatkan *quantum kernels* dalam menangkap pola nonlinear pada data iklim. Hal ini memvalidasi premis bahwa teknik QML berpotensi mengungguli model DL klasik untuk tugas regresi iklim yang kompleks, termasuk prediksi GFD (Pandey dkk. 2025).

Penelitian lain yang mengimplementasikan QNN menggunakan *Qiskit* untuk memprediksi *global horizontal irradiance* (GHI) menunjukkan bahwa QNN mampu memberikan hasil yang kompetitif untuk horizon peramalan 5 hingga 120 menit dan bahkan mengungguli pendekatan klasik seperti SVR dan GMDH pada horizon 180 menit. Hal ini menunjukkan kapasitas QNN dalam mengidentifikasi dan mengekstrak informasi spatiotemporal dari data, serta potensi keunggulannya pada horizon peramalan yang lebih panjang, yang relevan untuk sistem peringatan dini bencana terkait GFD tinggi oliveira2024QNN.

Pada prediksi kecepatan angin, yang juga dipandang sebagai fenomena atmosfer yang sangat *chaotic*, QNN menunjukkan potensi untuk mengungguli RNN klasik dalam hal akurasi dan kemampuan beradaptasi terhadap perubahan data yang mendadak. Kemampuan QNN untuk lebih tahan terhadap data yang sangat bervariasi dan *noisy* ini sangat relevan untuk prediksi GFD di wilayah tropis yang dikenal memiliki variabilitas tinggi (Silva dkk. 2025).

Studi lain mengevaluasi berbagai classifier termasuk SVM klasik, QSVC, dan VQC pada simulator kuantum IBM dan komputer kuantum IBM 127-qubit menggunakan

data iklim dan cuaca Earth Observation dari NASA bersama pustaka Qiskit ML. Hasilnya menunjukkan bahwa dua model kuantum (QSVC dan VQC) mampu memprediksi label kelas dengan kualitas yang wajar hanya dengan menggunakan dua *qubit*, yang menegaskan kelayakan teknis penerapan QML berbasis Qiskit dengan data satelit untuk aplikasi iklim dan cuaca (Munasinghe dkk. 2024).

Dalam konteks cuaca ekstrem, studi lain melaporkan bahwa model kuantum mampu meningkatkan akurasi prediksi hingga 92% untuk badai tropis dan sekaligus mempercepat waktu komputasi dari 48 jam menjadi 5 jam dibandingkan model konvensional. Temuan ini menguatkan hipotesis bahwa QNN memiliki keunggulan komputasi yang relevan untuk memprediksi fenomena cuaca ekstrem, termasuk GFD tinggi (Rith, Vann, dan Santos June 2025).

II.6.2 Identifikasi Gap Penelitian

Dari perspektif geografis dan standar rekayasa, standar proteksi petir internasional seperti IEC, NFPA, IEEE, JIS, dan NEMA saat ini dikembangkan terutama berdasarkan karakteristik petir subtropis. Hal ini menimbulkan ketidaksesuaian ketika standar tersebut diterapkan di wilayah tropis, sehingga mendorong Indonesia untuk mengembangkan bidang penelitian dan lokasi uji seperti Stasiun Penelitian Petir Gunung Tangkuban Perahu (SPP-TP) dan lokasi di Bogor (SPP-Bogor) untuk mengkaji dan menginovasi sistem proteksi petir tropis (Denov dan Zoro 2025).

Sebagaimana telah dijelaskan, terdapat disparitas signifikan antara perilaku petir di iklim tropis dan subtropis, dan investigasi selama delapan tahun di SPP-TP mengungkap berbagai atribut unik petir tropis (Denov dkk. September 2023). Perbedaan ini menimbulkan kebutuhan akan model prediksi yang adaptif secara regional, yang tidak dapat dipenuhi oleh model QML yang dikembangkan hanya berdasarkan data iklim Amerika Utara atau Eropa yang umumnya beriklim subtropis atau lintang menengah (Denov dan Zoro 2025).

Dari perspektif metodologis, aplikasi ML yang memanfaatkan data EO untuk memprediksi fenomena iklim memang sudah ada, namun kemampuan model-model tersebut untuk beradaptasi dari satu wilayah ke wilayah lain masih belum banyak dieksplorasi. Kesenjangan ini memperkuat urgensi penelitian yang tidak hanya mengembangkan QNN, tetapi juga menguji kemampuan generalisasi dan adaptasinya terhadap dua rezim iklim berbeda (tropis versus subtropis) yang memiliki karakteristik lightning flash yang berlainan (Munasinghe dkk. 2024).

Selain kesenjangan geografis, terdapat pula kesenjangan teknis terkait hardware kuantum yang masih dalam tahap pengembangan, sehingga membatasi aplikasi praktis dalam skala besar. Studi tersebut menekankan bahwa penelitian lanjutan diperlukan untuk mengembangkan sistem kuantum yang lebih stabil dan andal agar mampu memproses data cuaca yang lebih kompleks. Tesis ini diharapkan berkontribusi dengan menunjukkan bagaimana QNN dapat mencapai keunggulan komputasi dalam memodelkan interaksi variabel GFD tropis meskipun menggunakan sirkuit kuantum dangkal yang sesuai dengan keterbatasan perangkat NISQ dan ekosistem *qiskit* saat ini (Rith, Vann, dan Santos June 2025).

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Prediksi GFD dan parameter petir saat ini masih didominasi oleh model numerik dan algoritma ML klasik yang memiliki keterbatasan dalam menangkap proses fisik atmosfer yang kompleks serta sangat bergantung pada *feature engineering* manual. Walaupun pendekatan DL seperti CNN dan LSTM telah digunakan untuk *nowcasting*, model-model ini menuntut biaya komputasi yang tinggi dengan jutaan parameter dan kerap mengalami kesulitan generalisasi pada kejadian ekstrem akibat sifat atmosfer yang *chaotic*. Tantangan lainnya adalah ketidaksesuaian standar proteksi internasional yang berbasis data subtropis bila diterapkan di Indonesia, mengingat wilayah tropis memiliki karakteristik awan CB dan parameter petir yang lebih intensif. Di sisi lain, potensi komputasi kuantum atau QML sejauh ini baru diuji pada variabel cuaca umum seperti suhu dan angin, namun belum dimanfaatkan secara spesifik untuk memodelkan GFD maupun mengintegrasikan data global dan lokal guna mengatasi disparitas iklim tersebut di era NISQ ini.

III.2 Analisis Kebutuhan

III.2.1 Identifikasi Masalah Pengguna

Metode komputasi klasik saat ini memiliki keterbatasan dalam menangani sistem atmosfer yang *chaotic* dan memakan biaya komputasi tinggi akibat kompleksitas parameter fisik yang terlibat. Meskipun teknologi komputasi kuantum telah menunjukkan potensi besar dalam menangani pola nonlinear pada parameter cuaca umum seperti kecepatan angin, penerapannya belum pernah dilakukan secara spesifik untuk memprediksi GFD. Kesenjangan ini menghambat pemanfaatan keunggulan *superposition* dan *entanglement* untuk menyelesaikan masalah prediksi petir yang sulit dijangkau metode konvensional.

Kendala utama bagi pengguna adalah ketiadaan formulasi pemetaan matematis (*mapping*) yang tervalidasi, yang memungkinkan input variabel atmosfer dikonversi langsung menjadi nilai estimasi GFD. Pendekatan saat ini masih sangat bergantung pada ekstraksi fitur manual yang rumit dan sering kali mengabaikan keterkaitan fisika dasar pemicu petir. Hal ini menciptakan kebutuhan mendesak akan suatu fungsi prediktor komputasi yang praktis, dengan parameter cuaca dapat dimasukkan ke dalam sirkuit teroptimasi untuk menghasilkan luaran nilai GFD yang akurat.

Akurasi prediksi semakin sulit dicapai akibat disparitas karakteristik yang signifikan antara petir tropis dan subtropis. Standar proteksi dan model prediksi yang tersedia saat ini umumnya dikembangkan berbasis data subtropis, sehingga menimbulkan bias dan ketidaksesuaian ketika diterapkan di wilayah tropis. Kondisi ini menyulitkan pengguna dalam menghitung GFD yang reliabel karena belum adanya model yang terbukti mampu melakukan generalisasi pada kedua domain iklim yang berbeda tersebut.

III.2.2 Kebutuhan Fungsional

Berdasarkan identifikasi masalah pengguna, kebutuhan fungsional model ditunjukkan pada Tabel III.1.

Tabel III.1 Kebutuhan Fungsional Model Prediksi GFD Berbasis QNN

ID	Kebutuhan Fungsional	Deskripsi Detail
F-01	Prediksi GFD QNN	Menerima input fitur meteorologis dan menghasilkan output estimasi nilai GFD untuk suatu grid/wilayah.
F-02	Pemodelan Pola Tropis Versus Subtropis	Mengakomodasi penandaan domain atau koordinat geografis serta mampu membedakan pola GFD pada kedua rezim iklim melalui analisis error.
F-03	Eksperimen Generalisasi Lintas Domain	Memungkinkan skenario <i>train-on-tropics</i> , <i>test-on-subtropics</i> (dan sebaliknya) serta menyediakan pipeline komparasi performa <i>cross-domain</i> vs <i>in-domain</i> .
F-04	Evaluasi	Menyediakan fungsi evaluasi.
F-05	Manajemen Eksperimen & Konfigurasi	Menyimpan konfigurasi agar dapat direplikasi, serta fungsi simpan/panggil model terlatih.

III.2.3 Kebutuhan Nonfungsional

Berdasarkan identifikasi masalah pengguna, kebutuhan nonfungsional model ditunjukkan pada Tabel III.2.

Tabel III.2 Kebutuhan Nonfungsional Model Prediksi GFD Berbasis QNN

ID	Kebutuhan Nonfungsional	Target Kuantitatif / Deskripsi Terukur
NF-01	Akurasi	<i>Normalised Root Mean Square Error</i> (NRMSE) < 0.1 dan Koefisien Determinasi (R^2) > 0.9 .
NF-02	<i>Reproducibility</i>	Eksperimen harus dapat direplikasi dengan hasil dokumentasi.
NF-03	<i>Robustness</i>	Tidak <i>overfit</i> dengan memanfaatkan <i>training-validation-test split</i> .

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Alternatif dari pemilihan solusi dibagi menjadi pendekatan-pendekatan algoritma QML yang telah dibahas pada studi literatur.

1. *Quantum Generative Adversarial Networks* (QGAN)
2. *Quantum Neural Network* (QNN)
3. *Quantum Support Vector Regression* (QSVR)
4. *Quantum K Nearest Neighbors* (QkNN)
5. *Quantum Decision Tree* (QDT)

III.3.2 Analisis Penentuan Solusi

Penentuan solusi dilakukan berdasarkan parameter penilaian berikut.

1. *Suitability for Regression* (GFD): Seberapa alami algoritma tersebut beradaptasi untuk memprediksi nilai numerik kontinu (densitas)? Beberapa algoritma pada dasarnya adalah *classifiers* (pengklasifikasi) dan memerlukan modifikasi yang kompleks untuk dapat menghasilkan nilai *density*.
2. *Handling High-Dimensional Data* (Fitur Meteorologi): Data meteorologi (Suhu, Kelembapan, Tekanan, CAPE, *Shear*) bisa menjadi sangat kompleks. Seberapa efisien algoritma tersebut dapat memetakan fitur klasik ini ke dalam *Hilbert space* kuantum (efisiensi *Feature Map*)?
3. *Noise Resilience* (Era *NISQ*): Komputer kuantum saat ini memiliki tingkat *noise* yang tinggi. Seberapa baik kinerja algoritma tanpa adanya *error cor-*

rection yang sempurna? (Metode *Kernel* sering kali menoleransi *noise* lebih baik daripada *deep circuits*).

4. *Training Stability Convergence*: Seberapa mudah algoritma tersebut untuk dilatih? (misalnya, kemampuan menghindari *Barren Plateaus* pada QNN atau *mode collapse* pada QGAN).
5. *Qiskit Implementation Maturity*: Seberapa siap dan tersedia *library* serta *primitives* dalam ekosistem Qiskit saat ini (khususnya *Qiskit Machine Learning*)?

Masing-masing parameter dibobotkan pada Tabel III.3. Penentuan bobot kriteria ini didasarkan pada prioritas utama penelitian, yaitu kemampuan model dalam mengolah kompleksitas data meteorologi. Kriteria *Handling Complex Meteo Features* diberikan bobot dominan sebesar 50%, karena fenomena petir (GFD) melibatkan interaksi variabel cuaca yang sangat nonlinear dan berdimensi tinggi, sehingga kemampuan *Feature Map* dalam merepresentasikan data tersebut menjadi faktor penentu utama akurasi. Sementara itu, aspek *Noise Resilience* dan *Training Stability* diberikan bobot yang lebih rendah (total 15%) karena penelitian ini difokuskan pada validasi algoritma menggunakan simulasi (*quantum simulator*) yang ideal, sehingga kendala *noise* perangkat keras (*NISQ*) dapat diminimalisir dan bukan menjadi hambatan utama dalam tahap eksperimen ini.

Masing-masing algoritma dinilai dengan skala penilaian berikut.

1. 4 - Sangat Baik / Sangat Sesuai (*Excellent*):
Algoritma memiliki kemampuan superior dalam memenuhi kriteria, dukungan *library* yang matang, atau karakteristik yang sangat tepat untuk menyelesaikan masalah regresi GFD tanpa modifikasi besar.
2. 3 - Baik / Sesuai (*Good*):
Algoritma mampu memenuhi kriteria dengan baik dan dapat diandalkan, namun masih memiliki sedikit keterbatasan teknis atau kinerja dibandingkan dengan skor 4.
3. 2 - Cukup / Kurang Sesuai (*Fair*):
Algoritma dapat digunakan namun memerlukan modifikasi signifikan, upaya komputasi yang besar, atau secara teoritis kurang optimal untuk karakteristik data meteorologi.
4. 1 - Kurang / Tidak Sesuai (*Poor*):
Algoritma memiliki keterbatasan fundamental untuk kriteria tersebut, sangat sulit diimplementasikan, atau tidak dirancang untuk tujuan prediksi nilai kontinu (regresi).

Berdasarkan penilaian pada Tabel III.3, QNN ditetapkan sebagai metode utama yang

Tabel III.3 Matriks Perbandingan dan Pembobotan Algoritma Kuantum untuk Prediksi GFD


No	Criteria	Weight	QNN	QSVR	QGAN	QkNN	QDT
1	<i>Suitability for Regression (GFD)</i>	20%	4	4	1	2	2
2	<i>Handling Complex Meteo Features</i>	50%	4	3	1	2	3
3	<i>Noise Resilience (NISQ)</i>	10%	2	4	2	3	3
4	<i>Training Stability</i>	5%	2	4	1	4	3
5	<i>Qiskit Implementation Maturity</i>	15%	4	4	3	1	1
TOTAL SCORE		100%	3.70	3.50	1.40	2.05	2.50

akan digunakan. QNN mendapatkan skor sempurna (4) pada kemampuan menangani fitur kompleks. Arsitektur VQC pada QNN memungkinkan parameter dalam *feature map* untuk ikut dilatih (*trainable*), sehingga model dapat belajar representasi data cuaca yang paling optimal secara adaptif. Meskipun QNN memiliki kelemahan pada stabilitas pelatihan akibat fenomena *Barren Plateaus* (Skor 2), dampak negatif ini diredam oleh bobot kriteria stabilitas yang kecil (5%). Dukungan pustaka Qiskit yang matang (Skor 4) juga memastikan implementasi QNN dapat dilakukan secara efisien.


BAB IV

DESAIN KONSEP SOLUSI

Sesuai dengan metodologi yang sudah ditentukan, langkah-langkah pengembangan model prediksi GFD dapat dilihat pada Gambar IV.1. Proses dimulai dengan tahap pemahaman bisnis untuk menetapkan tujuan dan rencana proyek, diikuti oleh pemahaman data guna mengumpulkan serta memvalidasi kualitas data awal. Data tersebut kemudian diproses melalui tahap persiapan data yang mencakup pembersihan dan pemformatan agar siap digunakan dalam tahap pemodelan dengan algoritma diterapkan dan dioptimalkan. Setelah itu, model melalui tahap evaluasi untuk memastikan efektivitasnya dalam menjawab kebutuhan bisnis sebelum akhirnya masuk ke tahap *Deployment* untuk diimplementasikan ke dalam operasional nyata atau disajikan sebagai laporan akhir.



Gambar IV.1 Metodologi CRISP-DM



Gambar IV.2 Desain Konsep Solusi

Sistem ini dibangun di atas fondasi data meteorologis hibrida yang menggabungkan pengamatan lokal dan global untuk menganalisis karakteristik petir. Sumber data utama terdiri dari *dataset* sambaran petir lokal dari institusi seperti PLN yang mencatat lokasi dan waktu kejadian secara presisi di wilayah tropis Indonesia, serta *dataset* satelit NASA yang menyediakan informasi global mengenai kilatan cahaya (*flashes*) dan GFD, khususnya di wilayah subtropis. Integrasi kedua *dataset*

ini memberikan gambaran komprehensif mengenai pola aktivitas petir di berbagai zona iklim yang berbeda.

Sebelum data tersebut dimasukkan ke dalam model, dilakukan serangkaian proses pra-pemrosesan melalui modul pengolahan data. Tahap ini berfokus pada sinkronisasi resolusi spasial dan temporal untuk menyelaraskan sistem *grid* antar-*dataset* serta melakukan kalkulasi nilai GFD per *grid*. Selain itu, dilakukan normalisasi dan *scaling* fitur agar data numerik tersebut kompatibel dengan mekanisme *encoding* kuantum, misalnya dengan menyesuaikan rentang nilai agar dapat direpresentasikan sebagai sudut rotasi dalam sirkuit kuantum.

Inti dari pemrosesan cerdas sistem ini terletak pada modul Qiskit yang mengimplementasikan algoritma QNN. Proses komputasi dimulai dengan penggunaan *feature map*, seperti *angle encoding* atau lainnya, yang bertugas memetakan fitur meteorologis klasik ke dalam *state qubit*. *Output* regresi GFD akhirnya diperoleh yang menghitung *expectation value* dari sirkuit kuantum tersebut.

Untuk memastikan validitas dan keandalan model, sistem dilengkapi dengan modul evaluasi dan analisis yang komprehensif. Modul ini menerapkan fungsi evaluasi terstandarisasi yang memungkinkan evaluasi adil model QNN. Analisis difokuskan pada perbandingan performa di dua domain geografis utama—tropis dan subtropis, serta pengujian skenario *cross-domain* untuk mengukur sejauh mana model mampu mengelaborasi pola petir dari satu wilayah iklim ke wilayah lainnya.

Perbedaan signifikan antara sistem saat ini dan sistem yang diusulkan terletak pada pendekatan integrasi data serta paradigma komputasi yang diterapkan. Sistem yang ada saat ini umumnya masih bergantung pada model numerik, statistik klimatologis, atau ML klasik yang cenderung dikembangkan berdasarkan karakteristik wilayah subtropis, dengan integrasi yang terbatas antara data lokal tropis (PLN) dan data global (NASA). Sebaliknya, sistem yang diusulkan menawarkan solusi QML yang menyatukan kedua sumber data tersebut ke dalam satu *pipeline* analitik terpadu dengan penandaan domain yang jelas. Jika sebelumnya belum ada pemanfaatan teknologi kuantum, sistem baru ini menyediakan jalur pemodelan QNN berbasis VQC.

BAB V

RENCANA SELANJUTNYA

Bab ini merinci strategi eksekusi penelitian selama 16 minggu ke depan untuk mengembangkan dan memvalidasi model prediksi GFD berbasis QNN. Rencana ini disusun secara sistematis mengikuti kerangka kerja CRISP-DM, mulai dari penyiapan data meteorologis yang kompleks hingga evaluasi lintas domain iklim.

V.1 Rencana Implementasi

Pelaksanaan penelitian dibagi ke dalam empat fase bulanan yang berurutan. Fase pertama, yang berlangsung pada minggu ke-1 hingga ke-4, difokuskan sepenuhnya pada persiapan data dan rekayasa fitur. Kegiatan ini dimulai dengan akuisisi data petir dari PLN dan satelit NASA atau data atmosfer lainnya, yang kemudian disinkronisasi ke dalam grid spasial. Mengingat keterbatasan *qubit*, reduksi dimensi dilakukan secara ketat untuk memampatkan puluhan variabel cuaca menjadi fitur utama yang siap dikodekan ke dalam sirkuit kuantum.

Memasuki bulan kedua (minggu ke-5 hingga ke-8), fokus beralih pada pengembangan arsitektur model dan lingkungan komputasi. Pada tahap ini, peneliti akan membangun sirkuit variasional menggunakan *Qiskit*, memilih *feature map* untuk menangkap korelasi nonlinear, dan merancang algoritma yang efisien. Sistem pelatihan hibrida klasik-kuantum akan diimplementasikan untuk tahan terhadap noise, disertai dengan memastikan stabilitas konvergensi model sebelum pelatihan skala penuh dilakukan.

Fase eksperimentasi utama dilaksanakan pada bulan ketiga (minggu ke-9 hingga ke-12). Kegiatan inti pada fase ini adalah melatih dua model terpisah, yaitu model domain tropis menggunakan data Indonesia dan model domain subtropis menggunakan data global. Setelah model terlatih, serangkaian uji silang (*cross-domain testing*) dilakukan dengan menerapkan model tropis pada data subtropis dan seba-

liknya. Tujuannya adalah untuk mengukur kesenjangan generalisasi (*generalization gap*) sebagai bukti empiris adanya disparitas karakteristik petir antar-wilayah.

Bulan terakhir (minggu ke-13 hingga ke-16) didedikasikan untuk analisis, interpretasi, dan penyusunan laporan. Peneliti akan melakukan interpretasi fisika terhadap hasil prediksi. Seluruh temuan akan didokumentasikan dalam Tugas Akhir 2, dilanjutkan dengan revisi naskah bersama dosen pembimbing dan persiapan materi presentasi untuk sidang akhir skripsi.

V.2 Desain Pengujian dan Evaluasi

Evaluasi kinerja model dirancang untuk menjawab hipotesis penelitian melalui pendekatan komparatif yang ketat di lingkungan simulator *Qiskit*. Pengujian akan dilaksanakan dalam tiga skenario utama, *benchmarking* model QNN untuk memvalidasi kelayakan teknis, pengujian *in-domain* untuk menetapkan akurasi dasar, dan pengujian *cross-domain* untuk menganalisis penurunan performa saat model diterapkan pada iklim yang berbeda.

Untuk mengukur keberhasilan prediksi secara kuantitatif, penelitian ini menggunakan metrik RMSE sebagai indikator utama deviasi prediksi GFD, dilengkapi dengan koefisien determinasi untuk melihat kemampuan model dalam menjelaskan *varians* data. Selain angka statistik, analisis kualitatif dilakukan menggunakan visualisasi guna mengidentifikasi apakah model memiliki kelemahan spesifik pada topografi tertentu, seperti wilayah pegunungan atau lautan.

V.3 Analisis Risiko dan Mitigasi

Pengembangan model kuantum pada era NISQ menghadapi risiko teknis utama berupa fenomena *Barren Plateaus*, dengan gradien menghilang sehingga model gagal belajar. Untuk memitigasi hal ini, penelitian akan menggunakan sirkuit kuantum yang dangkal (*shallow circuits*), teknik inisialisasi parameter identitas, serta fungsi biaya lokal yang lebih stabil. Risiko teknis lainnya adalah waktu tunggu antrian yang lama pada perangkat keras IBM Quantum, yang akan diatasi dengan memprioritaskan penggunaan simulator lokal berkinerja tinggi untuk sebagian besar eksperimen dan hanya menggunakan perangkat keras nyata untuk validasi akhir sampel kecil.

Dari sisi data, terdapat risiko *sparsity* atau banyaknya nilai nol pada data satelit akibat keterbatasan waktu lintas orbit. Mitigasi dilakukan dengan melakukan agregasi

temporal data (misalnya menjadi rata-rata bulanan) untuk mengisi kekosongan data observasi. Terakhir, untuk mengantisipasi risiko manajemen waktu akibat kompleksitas pemrograman hibrida, akan diterapkan solusi dengan pipeline sederhana diselesaikan terlebih dahulu sebelum meningkatkan kompleksitas model secara bertahap jika waktu memungkinkan.

DAFTAR PUSTAKA

- Achmad Imam Agung dan Mahendra Widyartono, Arif Karta dan. 2020. “Analisis Kebutuhan Sistem Proteksi Sambaran Petir Pada Gedung Bertingkat”. *Jurnal Teknik Elektro* 9 (3).
- Amri, Muhammad Fadhil. 2024. “Prediksi Kerapatan Petiru Menggunakan Quantum Support Vector Regression”. Skripsi, Institut Teknologi Bandung.
- Basheer, Afrad, A. Afham, dan Sandeep K. Goyal. 2024. *Quantum k nearest neighbors algorithm*. Study presented at Centre for Quantum Software and Information, University of Technology, Sydney.
- Beer, Kerstin. 2022. *Quantum neural networks*. Dissertation, Gottfried Wilhelm Leibniz Universität Hannover.
- Cheng, W.-Y. and Kim, D. and Ham, Y.-G. and Henderson, T. E. 2024. “Machine Learning–Based Lightning Parameterizations for the CONUS”. *Artificial Intelligence for the Earth Systems*, no. e230024.
- Denov, Bryan, Syarif Hidayat, Reynaldo Zoro, dan Suwarno. 2022. “Tropical Lightning Peak Current Measurement at West Java, Indonesia”. Dalam *2022 36th International Conference On Lightning Protection (ICLP)*. IEEE. <https://doi.org/10.1109/ICLP56858.2022.9942478>. <https://www.researchgate.net/publication/365444699>.
- . September 2023. “A Method to Obtain Lightning Peak Current in Indonesia”. *Energies* 16, no. 6342 ().
- Denov, Bryan, dan Reynaldo Zoro. 2025. “Review of NFPA 780 Standard Compliance for Improved Lightning Protection in Indonesia’s Oil and Gas Industry”. *Energies* 18 (4002).
- Javadi-Abhari, A., dan et al. 2024. *Quantum computing with Qiskit*.

- Li, Zhelun, dan Koji Terashi. 2025. “Quantum decision trees with information entropy”. *International Center for Elementary Particle Physics (ICEPP)*.
- Mäkelä, Antti, Pekka Rossi, dan David M. Schultz. 2011. “The Daily Cloud-to-Ground Lightning Flash Density in the Contiguous United States and Finland”. *Monthly Weather Review* 139 (5): 1323–1337. <https://doi.org/10.1175/2010MWR3517.1>.
- Marella, Surya Teja, dan Hemanth Sai Kumar Parisa. 2020. “Introduction to Quantum Computing”. Dalam *Selection of our books indexed in the Book Citation Index*.
- Munasinghe, Thilanka, Phung Lai, Jennifer Wei, James Hendler, dan Kimberly A. Cornell. 2024. “Assessment of Quantum ML Applicability for Climate Actions: Comparison of the Variational Quantum Classifier and the Quantum Support Vector Classifier with Classical ML Models”.
- Nicora, Martino, Mauro Tucci, Sami Barmada, Massimo Brignone, dan Renato Procopio. June 2024. “Lightning Location and Peak Current Estimation From Lightning-Induced Voltages on Transmission Lines With a Machine Learning Approach”. *IEEE Transactions on Electromagnetic Compatibility* 3, no. 66 ().
- Nokhwal, Sahil, Suman Nokhwal, Saurabh Pahune, dan Ankit Chaudhary. 2023. *Quantum Generative Adversarial Networks: Bridging Classical and Quantum Realms*. Pioneering research paper exploring synergistic fusion of classical and quantum computing paradigms within Generative Adversarial Networks (GANs).
- Pandey, Trilok Nath, Vishvajeet Rajasekar, Sunil Kumar Pradhan, dan Sidharth D Nair. 2025. “A comparative analysis of classical machine learning models with quantum-inspired models for predicting world surface temperature”.
- Peterson, Michael, Douglas Mach, dan Dennis Buechler. 2021. “A Global LIS/OTD Climatology of Lightning Flash Extent Density”. *Journal of Geophysical Research: Atmospheres*.
- Rith, Vicheka, Dara Vann, dan Luis Santos. June 2025. “Quantum Computing to Forecast Extreme Weather”. *Journal of Tecnologia Quantica* 2, no. 3 (): 125–134.

- Sahin, M. Emre, Edoardo Altamura, Oscar Wallis, Stephen P. Wood, Anton Dekusar, Declan A. Millar, Takashi Imamichi, Atsushi Matsuo, Stefano Mensa, dan Code contributors. 2025. "Qiskit Machine Learning: an open-source library for quantum machine learning tasks at scale on quantum hardware and classical simulators".
- Silva, Maria Helóisa F. da, Gleydson F. de Jesus, Christiano M. S. Nascimento, Valéria L. da Silva, dan Clebson S. Cruz. 2025. "Exploring Quantum Machine Learning for Weather Forecasting".
- Society, American Meteorology. 2022. *Lightning*. <https://glossary.ametsoc.org/wiki/Lightning>.
- Sutor, Robert S. 2019. *Dancing with Qubits*. Packt Publishing.
- Tscharke, Kilian, Maximilian Wendlinger, Sebastian Issel, dan Pascal Debus. 2024. *Quantum Support Vector Regression for Robust Anomaly Detection*. Fraunhofer Institute for Applied and Integrated Security (AISEC).
- Vahid Yousefnia, Kianusch, Tobias Bölle, Isabella Zöbisch, dan Thomas Gerz. 2024. "A machine-learning approach to thunderstorm forecasting through post-processing of simulation data". *Quarterly Journal of the Royal Meteorological Society* 150 (763).
- Wang, X., K. Hu, Y. Wu, dan W. Zhou. November 2023. "A Survey of Deep Learning-Based Lightning Prediction". *Atmosphere* 14, no. 1698 ().
- Webster, Jane, dan Richard T. Watson. 2002. "Analyzing the Past to Prepare for the Future: Writing a Literature Review". *MIS Quarterly* 26 (2): xiii–xxiii.
- Zhou, K., Y. Zheng, W. Dong, dan T. Wang. 2020. "A deep learning network for cloud-to-ground lightning nowcasting with multisource data". *Journal of Atmospheric and Oceanic Technology* 37 (5).